

UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY



FACULTAD DE
INGENIERÍA

# Proceso asistido por inteligencia artificial para la extracción, anonimización y generación de bases de datos de preproducción para testing

**Informe de avance: relevamiento del estado del arte**

Informe de Proyecto de Grado presentado por

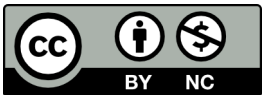
Jerónimo Jacques Balma y Virginia Paola Romay Bermúdez

en cumplimiento parcial de los requerimientos para la graduación de la carrera de Ingeniería en Computación de Facultad de Ingeniería de la Universidad de la República

Supervisores

Nombre Supervisor
Nombre Co-Supervisor

Montevideo, Setiembre de 2026



**Proceso asistido por inteligencia artificial para la extracción, anonimización y generación de bases de datos de preproducción para testing**

**Informe de avance: relevamiento del estado del arte** por Jerónimo Jacques Balma y Virginia Paola Romay Bermúdez tiene licencia CC Atribución - No Comercial 4.0.

# Resumen

Este documento constituye un informe de avance del Proyecto de Grado y presenta el relevamiento del estado del arte realizado durante sus primeras semanas. El objetivo general del proyecto consiste en diseñar un proceso asistido por inteligencia artificial que permita generar bases de datos de preproducción seguras y representativas para testing a partir de datos productivos, garantizando la no exposición de información sensible.

El problema abordado radica en la dificultad de balancear seguridad y utilidad. Utilizar un respaldo directo maximiza el realismo a costa de un alto riesgo de exposición. Por el contrario, la generación de datos enteramente ficticios mitiga este riesgo, pero sacrifica el rigor estadístico, la cardinalidad y la representación de casos límite. Asimismo, las técnicas de enmascaramiento puntual mediante scripts suelen ser frágiles ante cambios estructurales y deficientes al tratar identificadores indirectos.

El relevamiento se estructuró distinguiendo entre transformaciones deterministas y modelos generativos, clasificando las herramientas disponibles según la función que cumplen dentro del proceso: generación sin datos reales, anonimización a nivel de motor de base de datos, anonimización formal, gestión integral de datos de prueba, síntesis tabular generativa, detección de datos sensibles, y validación de fidelidad y privacidad. Para cada herramienta analizada se documentan sus capacidades, su modelo de licenciamiento, la viabilidad de ejecución en un entorno aislado y las limitaciones particulares para el caso de uso del proyecto. Este análisis se consolida mediante matrices comparativas de costo, eficiencia computacional, despliegue, parametrización, y cobertura de motores de bases de datos.

Los resultados evidencian que ninguna herramienta soluciona el problema de manera integral, sino que actúan de forma complementaria. Mientras el enmascaramiento determinista aporta integridad y auditabilidad, los modelos generativos proporcionan distribuciones realistas y volumen. A su vez, ninguno de los dos aborda el descubrimiento de los activos a proteger, área donde un modelo de lenguaje demuestra un valor añadido considerable. A partir de este diagnóstico, se propone una arquitectura de referencia en capas —introspección, clasificación, extracción de subconjuntos, transformación, validación y trazabilidad— y se postula una pila tecnológica compuesta en su totalidad por componentes de licencia permisiva y ejecución local. Finalmente, se identifican como principales problemas abiertos la preservación de la integridad referencial al sintetizar da-

tos relacionales y la ausencia de métricas de utilidad orientadas específicamente a testing de software, visualizando esta última como la oportunidad principal para realizar un aporte original dentro del proyecto.

**Palabras clave:** Datos sintéticos, Anonimización, Datos de prueba, Integridad referencial, Privacidad

# Índice general


**1. Introducción** **1**
- 1.1. Planteamiento del problema . . . 1
- 1.2. Objetivos . . . 1
- 1.3. Resultados esperados de esta etapa . . . 2
- 1.4. Organización del documento . . . 2

**2. Revisión de antecedentes** **3**
- 2.1. Marco conceptual . . . 3
  - 2.1.1. Taxonomía de técnicas de protección de datos . . . 3
  - 2.1.2. Marco regulatorio aplicable . . . 4
  - 2.1.3. Enfoque determinista frente a enfoque generativo . . . 4
  - 2.1.4. Por qué el enfoque tiene que ser híbrido . . . 5
  - 2.1.5. Linaje de modelos generativos tabulares . . . 5
- 2.2. Relevamiento de herramientas . . . 6
  - 2.2.1. Criterio de organización . . . 6
  - 2.2.2. Panorama de mercado y consolidación . . . 7
  - 2.2.3. Generadores sin datos reales . . . 8
  - 2.2.4. Anonimizadores a nivel de motor de base de datos . . . 9
  - 2.2.5. Anonimización formal: ARX . . . 10
  - 2.2.6. Suites comerciales de gestión de datos de prueba . . . 11
  - 2.2.7. Librerías de síntesis tabular . . . 11
  - 2.2.8. Detección de datos sensibles . . . 13
  - 2.2.9. Validación y evaluación . . . 14
  - 2.2.10. Rol de la inteligencia artificial en el proceso . . . 15
- 2.3. Matrices de comparación técnica . . . 16
  - 2.3.1. Costos y licenciamiento . . . 16
  - 2.3.2. Productividad y eficiencia . . . 16
  - 2.3.3. Despliegue dentro del perímetro propio . . . 17
  - 2.3.4. Parametrización y control . . . 17
  - 2.3.5. Matriz consolidada de decisión . . . 18
  - 2.3.6. Cobertura por motor de base de datos . . . 19
- 2.4. El problema técnico central: preservar la integridad referencial . . . 19
  - 2.4.1. Claves primarias . . . 19
  - 2.4.2. Claves foráneas e integridad referencial . . . 20

2.4.3. Extracción de subconjuntos con integridad referencial . . 20
2.4.4. Tipos de datos complejos . . . . . 20
2.5. Criterios de evaluación . . . . . 20
2.5.1. Un dato sintético no es un dato anónimo . . . . . 20
2.5.2. Utilidad para testing frente a utilidad para aprendizaje automático . . . . . 21
2.5.3. Privacidad diferencial: qué garantiza y qué no . . . . . 22

**3. Arquitectura de referencia y pila tecnológica propuestas 23**
3.1. Por qué la orquestación es necesaria . . . . . 23
3.2. Arquitectura de referencia por capas . . . . . 23
3.3. Consideraciones de implementación . . . . . 24
3.4. Pila tecnológica candidata . . . . . 24
3.5. Por qué esta combinación y no otra . . . . . 24

**4. Diseño experimental y riesgos 26**
4.1. Plan de validación . . . . . 26
4.2. Riesgos residuales a documentar . . . . . 26

**5. Conclusiones y trabajo futuro 28**
5.1. Conclusiones del relevamiento . . . . . 28
5.2. Preguntas de investigación abiertas . . . . . 29
5.3. Próximos pasos . . . . . 29

**Referencias 30**

**A. Manifiesto de trazabilidad 33**

# Capítulo 1

# Introducción

Las primeras semanas de ejecución del proyecto han sido destinadas al relevamiento y análisis del estado del arte. El propósito es comprender las técnicas y herramientas actuales empleadas para generar bases de datos de preproducción a partir de datos productivos, y analizar la integración de técnicas de inteligencia artificial en dicho flujo de trabajo. El enfoque de esta fase inicial no radica en la implementación de una solución definitiva, sino en categorizar el ecosistema tecnológico disponible y acotar de manera progresiva el alcance del proyecto.

## 1.1. Planteamiento del problema

El problema central del proyecto es la concepción de un mecanismo para generar una base de datos de preproducción que sea lo suficientemente representativa para entornos de pruebas, partiendo de datos productivos reales, sin trasladar información sensible a ecosistemas de menor seguridad. Esta dicotomía exige mantener la utilidad operativa de los datos para lograr pruebas fidedignas, reduciendo en paralelo el riesgo de exposición y reidentificación. Una anonimización excesiva invalida el valor de los datos para la ingeniería de calidad (QA), mientras que una transformación insuficiente perpetúa las vulnerabilidades de privacidad.

En la práctica industrial, existen tres enfoques principales para poblar un ambiente de pruebas, cada uno con limitaciones específicas que se detallan en la Tabla 1.1.

## 1.2. Objetivos

El objetivo general del proyecto se enfoca en explorar una vía alternativa a las soluciones previamente descritas: un proceso reproducible, con asistencia de inteligencia artificial, que extraiga un subconjunto coherente del ambiente de producción, aplique transformaciones con garantías medibles de privacidad, y proporcione una base de preproducción útil a nivel de QA y segura a nivel de

| Camino | Qué se hace | Por qué falla |
|---|---|---|
| Copia directa de producción | *Restore* de un respaldo productivo en el ambiente de prueba | Riesgo legal y de seguridad máximo. Los ambientes no productivos suelen tener controles de acceso, monitoreo y retención mucho más laxos que producción, con lo cual el dato personal termina en el lugar menos protegido de la organización. |
| Datos completamente inventados | Faker, Mockaroo o scripts de *seed* | No hay riesgo de privacidad, pero se pierde el realismo estadístico, la cardinalidad, los *outliers* y la "suciedad" del dato real. Los errores que aparecen en producción no se reproducen en testing. |
| Enmascaramiento manual | Scripts SQL de `UPDATE` artesanales | Frágil ante cambios de esquema, difícil de mantener consistente entre tablas, no verificable y típicamente incompleto: se enmascara lo obvio y se olvida lo indirecto. |

Tabla 1.1: Caminos habituales para poblar un ambiente de testing y sus fallas

exposición. La inteligencia artificial se incorpora como un componente orquestador o de apoyo —por ejemplo, clasificando la sensibilidad de los campos— y no como un motor monolítico de anonimización.

El objetivo específico de la etapa actual es relevar, describir y categorizar las técnicas y herramientas disponibles para la protección y generación de datos de prueba. Adicionalmente, se busca identificar los problemas técnicos que aún se encuentran sin resolver, lo que permitirá delimitar el espacio de investigación para el aporte original del proyecto.

## 1.3. Resultados esperados de esta etapa

Se prevé que el relevamiento permita (i) establecer un vocabulario técnico preciso sobre técnicas de protección de datos, (ii) elaborar una taxonomía funcional de las herramientas del sector, (iii) comparar objetivamente estas alternativas en base a los requisitos del proyecto, (iv) identificar las restricciones técnicas que condicionan cualquier arquitectura propuesta, y (v) señalar los espacios del estado del arte que el proyecto tiene potencial para cubrir. Las deducciones iniciales se exponen en el Capítulo 5.

## 1.4. Organización del documento

El Capítulo 2 aborda la revisión bibliográfica y técnica: introduce el marco conceptual y taxonómico (Sección 2.1), presenta el relevamiento de mercado por categoría funcional (Sección 2.2), consolida la comparación a través de matrices evaluativas (Sección 2.3), profundiza en el desafío técnico de preservar la integridad referencial (Sección 2.4) y analiza las métricas de evaluación, diferenciando la utilidad para QA de la utilidad para *machine learning* (Sección 2.5). El Capítulo 3 detalla la propuesta preliminar de una arquitectura de referencia y la pila tecnológica seleccionada. El Capítulo 4 esquematiza el diseño experimental futuro y los riesgos del modelo. Para concluir, el Capítulo 5 consolida las reflexiones obtenidas y los siguientes pasos.

# Capítulo 2

# Revisión de antecedentes

## 2.1. Marco conceptual

### 2.1.1. Taxonomía de técnicas de protección de datos

Previo a la comparación de herramientas, es indispensable establecer definiciones técnicas rigurosas, dado que la industria frecuentemente emplea estos conceptos de forma ambigua o intercambiable. Se identifican cinco categorías fundamentales (véase la Tabla 2.1).

| **Técnica** | **Qué hace** | **Estado legal del resultado** | **Reversible** |
|---|---|---|---|
| Enmascaramiento | Suprime o reemplaza valores de identificadores directos | Sigue siendo dato personal si quedan cuasi-identificadores | No (estático); el original persiste (dinámico) |
| Seudonimización | Reemplaza identificadores por referencias, guardando la información adicional por separado | Dato personal para quien tiene la información adicional | Sí, con la clave |
| Anonimización | Reduce el riesgo de identificación a un nivel suficientemente remoto | Fuera del régimen si pasa el test de criterios acumulativos | No |
| PETs | Tecnologías que minimizan, ocultan o fragmentan el dato durante su procesamiento | Depende: la mayoría no anonimiza | Varía |
| Datos sintéticos | Registros nuevos generados por un modelo que aprendió la distribución del original | No anónimos por defecto; requieren evaluación *ex post* | No directamente, pero atacable |

Tabla 2.1: Taxonomía de técnicas de protección de datos

La clasificación expuesta en la última fila posee gran relevancia para esta investigación. El ICO (*Information Commissioner's Office*) tipifica a los datos sintéticos como una técnica de randomización y estipula que su nivel de anonimato está sujeto a la imposibilidad de inferir los datos originales empleados en el entrenamiento (Information Commissioner's Office, 2025). Métodos de generación ampliamente utilizados han exhibido vulnerabilidades frente a ataques

de inversión de modelo, inferencia de membresía y divulgación de atributos. Por lo tanto, la generación de datos sintéticos constituye una técnica de mitigación de riesgos y no una garantía absoluta de anonimato.

### 2.1.2. Marco regulatorio aplicable

El precedente normativo clásico es la Opinión 05/2014 del Grupo de Trabajo del Artículo 29 (Article 29 Data Protection Working Party, 2014), donde se estipularon tres métricas de anonimización efectiva: aislamiento (*singling out*), enlazabilidad (*linkability*) e inferencia. Estos indicadores continúan siendo el estándar subyacente a las herramientas de auditoría descritas en la Sección 2.2.9. El borrador de las Guías 02/2026 del EDPB (European Data Protection Board, 2026) refina estos preceptos transformándolos en criterios acumulativos e impone dos directrices operativas que afectan directamente a este proyecto: la anonimización se considera un procesamiento de datos que demanda base legal, y existe la obligación estricta de documentar los testeos realizados sobre el conjunto de datos resultante. En consecuencia, la trazabilidad técnica pasa de ser una convención recomendada a un requisito insoslayable.

En Uruguay, la normativa rectora es la Ley N.º 18.331 (República Oriental del Uruguay, 2008) junto a su cuerpo complementario, siendo la URCDP la autoridad competente. Dicha ley define la disociación de datos como cualquier procesamiento en el cual la información resultante pierda su asociación con una persona determinada o determinable; concepto análogo a la anonimización del RGPD europeo. La URCDP ha provisto guías orientativas al respecto (URCDP, 2023). Debido a que Uruguay sostiene el estatus de adecuación con la Comisión Europea, estructurar la solución sobre los estándares del EDPB y del ICO garantiza la solvencia metodológica y legal a nivel nacional.

### 2.1.3. Enfoque determinista frente a enfoque generativo

La clasificación algorítmica fundamental del relevamiento distingue entre dos enfoques primarios.

El **enfoque determinista** se fundamenta en la aplicación de transformaciones explícitas por columna: reemplazo por valores semánticos, funciones *hash* con sal, generalización en rangos, permutaciones o adición de ruido acotado. Este paradigma destaca por su auditabilidad exhaustiva, la preservación innata del esquema relacional, un impacto computacional ínfimo y la nula exposición a riesgos de memorización (al no existir un modelo probabilístico subyacente). Adicionalmente, permite mantener consistencia entre tablas cruzadas mediante el uso de semillas idénticas en claves no formalizadas. Sin embargo, sus carencias radican en la destrucción de correlaciones multivariadas —la randomización individual de un código postal y una ciudad rompe su correspondencia lógica—, la incapacidad de emular distribuciones marginales sin codificación manual, y la restricción estricta sobre el volumen resultante (procesa un mapeo $1:1$). Requiere además un mapeo manual de sensibilidad que resulta inviable en bases de datos con cientos de tablas.

En contraposición, el **enfoque generativo** abstrae la distribución conjunta de la fuente a través del entrenamiento de un modelo, permitiendo el muestreo de datos nuevos. Preserva relaciones latentes no lineales, independiza el volumen del *dataset* resultante y posibilita el muestreo dirigido. Como contraparte, presenta problemáticas asociadas a la sobre-memorización, la carencia de mecanismos para forzar restricciones lógicas duras (pudiendo emitir fechas de vencimiento previas a la emisión), y un tratamiento deficiente de identificadores únicos debido a su distribución plana. Sumado a ello, implica altos costos computacionales y degradación de rendimiento en conjuntos altamente dimensionales o desbalanceados.

### 2.1.4. Por qué el enfoque tiene que ser híbrido

La Tabla 2.2 sintetiza los motivos por los cuales la adopción exclusiva de uno de los paradigmas resulta insuficiente en escenarios de preproducción.

| **Requisito de una base de preproducción** | **Determinista** | **Generativo** |
|---|---|---|
| Claves primarias únicas y estables | Sí | No |
| Claves foráneas que resuelven (integridad referencial) | Sí | Parcial (solo con modelo relacional específico) |
| Formatos que pasan las validaciones de la aplicación | Sí | Parcial |
| Restricciones de negocio (invariantes, sumas, fechas ordenadas) | Sí | No |
| Distribuciones marginales realistas | No | Sí |
| Correlaciones entre columnas | No | Sí |
| *Outliers* y casos borde realistas | No | Parcial |
| Volumen ajustable | No | Sí |
| Auditabilidad regulatoria | Sí | Parcial (requiere medición *ex post*) |
| Descubrimiento automático de qué proteger | No | No |

Tabla 2.2: Cobertura de los requisitos de una base de preproducción según enfoque

El aspecto resolutivo que legitima la integración de la inteligencia artificial, tal como se plantea en el objetivo, subyace en la última fila del cuadro: ninguno de los enfoques convencionales posee la heurística para discernir automáticamente qué columnas requieren protección, ni qué tratamiento corresponde según el rol semántico del campo dentro de un esquema relacional. Es precisamente en este proceso de inferencia y orquestación donde la integración de un modelo de lenguaje aporta capacidades distintivas.

### 2.1.5. Linaje de modelos generativos tabulares

Resulta pertinente trazar una línea temporal de estos modelos, considerando la rápida evolución del estado del arte y el hecho de que múltiples herramientas aún basan su documentación en arquitecturas de 2019. La Tabla 2.3 expone esta progresión.

| Generación | Modelos | Aporte | Limitación |
|---|---|---|---|
| Estadística clásica (pre-2019) | Cópulas gaussianas, synthpop, DataSynthesizer, modelos bayesianos | Rápidos, interpretables, sin GPU | Modelan marginales por separado y dependencias solo de a pares |
| GAN tabulares (2019–2022) | CTGAN, CTAB-GAN, CTAB-GAN+, ACTGAN (Xu, Skoularidou, Cuesta-Infante, y Veeramachaneni, 2019; Zhao, Kunar, Birke, y Chen, 2024) | Vector condicional y normalización por modo para continuas multimodales y desbalance de clases | Colapso de modos, entrenamiento inestable, mala escalabilidad |
| VAE tabulares | TVAE (Xu y cols., 2019) | Más estable que las GAN, buen desempeño en utilidad para aprendizaje automático | Colapso de la clase minoritaria bajo muestreo incondicional |
| Basados en árboles | SMOTE, ARF, UnmaskingTrees, condicionales con RandomForest/XGBoost | Muy bajo costo computacional, competitivos con redes neuronales en varios *benchmarks* | SMOTE tiene mal compromiso privacidad/utilidad: genera puntos demasiado cercanos a los originales |
| Difusión (2023–) | TabDDPM, CoDi, TabSyn, TabDiff, CDTD (Kotelnikov, Baranchuk, Rubachev, y Babenko, 2023) | Estado del arte en fidelidad para tabla única | Costo alto de entrenamiento e inferencia; sobreajuste documentado vía DCR |
| Autorregresivos (2023–) | REaLTabFormer, GReaT, TabMT, TabularARGN (Solatorio y Dupriez, 2023; Tiwald y cols., 2025) | Condicionan cada atributo en los anteriores dentro de la fila; TabularARGN usa torres por atributo en lugar de tratar la tabla como texto | Requieren cuidado con el orden de los atributos |
| Relacionales / multi-tabla | HMASynthesizer, RCTGAN, PrivLava, ClavaDDPM, RelDiff (Pang y cols., 2024; Cai, Xiao, y Cormode, 2023; Autores de RelDiff, 2025) | Modelan explícitamente relaciones padre-hijo y restricciones de clave foránea | Área menos madura (ver Sección 2.4) |

Tabla 2.3: Linaje de modelos generativos tabulares

A efectos de las decisiones arquitectónicas del presente proyecto, resulta fundamental la literatura reciente orientada a evaluación de arquitecturas. Un *benchmark* representativo sobre once corpus diferentes demostró que el modelo TabularARGN logra un rendimiento competitivo a un coste sustancialmente reducido (Tiwald y cols., 2025). En el mismo estudio se constató empíricamente que los modelos basados en difusión (CDTD, TabDDPM) tienden a generar muestras con extrema proximidad a los datos originales, señalizando un nivel problemático de sobreajuste. Paralelamente, los enfoques heurísticos basados en árboles de decisión mantienen métricas robustas compitiendo con redes neuronales complejas, configurándose como una alternativa muy favorable para implementaciones con recursos computacionales finitos.

## 2.2. Relevamiento de herramientas

### 2.2.1. Criterio de organización

El análisis del ecosistema se ha segmentado priorizando la *función específica dentro de la canalización de datos*, postergando clasificaciones por popularidad o licenciamiento. Esto obedece a que las distintas herramientas operan de forma complementaria sobre etapas discretas del proceso integral, el cual se divide en cinco funciones fundamentales:

1. **Descubrimiento**: identificación de topología de tablas, columnas y extracción de dependencias referenciales (declaradas e implícitas).
2. **Clasificación**: discriminación de campos sensibles acorde a criterios preestablecidos.
3. **Extracción** (*subsetting*): muestreo coherente de subgrafos de datos manteniendo la consistencia relacional.
4. **Transformación**: aplicación de enmascaramiento sobre identificadores y síntesis estocástica sobre las variables restantes.
5. **Validación**: cuantificación desacoplada de la utilidad y del riesgo de privacidad.

Mientras que las suites de gestión de grado empresarial abarcan las etapas iniciales de forma exhaustiva pero adolecen de mecanismos de validación transparentes, las librerías académicas de código abierto se enfocan exclusivamente en la síntesis y auditoría. La Tabla 2.4 provee un esquema conceptual detallando el alineamiento de cada categoría con estas cinco etapas.

| **Categoría** | **Función que cubre** | **Herramientas relevadas** | **Sección** |
|---|---|---|---|
| Generadores independientes | Transformación (parcial) | Faker, Mockaroo, Tonic Fabricate, NVIDIA NeMo Data Designer | 2.2.3 |
| Anonimizadores en el motor | Transformación determinista | PostgreSQL Anonymizer; enmascarado nativo de SQL Server, Oracle y MySQL | 2.2.4 |
| Anonimización formal | Transformación y validación | ARX | 2.2.5 |
| Suites comerciales de gestión de datos de prueba | Descubrimiento, clasificación, extracción y transformación | Tonic.ai, Perforce Delphix, Informatica TDM, IBM Optim, K2View, Redgate, DATPROF | 2.2.6 |
| Librerías de síntesis tabular | Transformación generativa | SDV, MOSTLY AI SDK, synthcity, REaLTabFormer, ClavaDDPM, NeMo Safe Synthesizer | 2.2.7 |
| Detección de datos sensibles | Clasificación | Microsoft Presidio, GLiNER / GLiNER2-PII, CASSED, modelos de lenguaje locales y comerciales | 2.2.8 |
| Validación y evaluación | Validación | SDMetrics, SyntheRela, SynthEval, Anonymeter, ARX (como validador) | 2.2.9 |

Tabla 2.4: Categorización funcional de las herramientas relevadas

### 2.2.2. Panorama de mercado y consolidación

Como contexto previo a la descripción técnica, cabe destacar que el sector atravesó una fuerte consolidación empresarial entre 2024 y 2026. Estos movi-

mientos estructurales dictaminan condicionantes operativos de cara a la selección tecnológica del proyecto.

| Evento | Fecha | Consecuencia |
|---|---|---|
| NVIDIA adquiere Gretel.ai | marzo 2025 | Gretel cesó operaciones como entidad independiente. Su motor subyacente transicionó hacia NVIDIA NeMo Data Designer, licenciado bajo NVIDIA AI Enterprise. Los repositorios de GitHub fueron congelados en 2026 sin soporte prospectivo. |
| Syntho adquiere la marca MOSTLY AI | junio 2026 | Operación unificada como "MOSTLY AI, powered by Syntho". El SDK distribuido bajo licencia Apache 2.0 mantiene su estatus activo. |
| Perforce adquiere Delphix | 2024 | Integración bajo la denominación "Perforce Delphix", manteniendo cadencia de lanzamientos. |
| DataCebo migra SDV a Business Source License | 2023–2024 | Migración masiva del ecosistema SDV desde MIT hacia BSL v1.1, con la excepción técnica de la librería de evaluación SDMetrics. |

Tabla 2.5: Movimientos de consolidación del sector relevantes para el proyecto

En consecuencia, un corolario clave para el diseño de la arquitectura es la alta exposición al riesgo (*vendor lock-in* u obsolescencia forzada) al depositar componentes críticos en librerías corporativas. Esto enfatiza la necesidad estratégica de cimentar el núcleo orquestador sobre proyectos de código abierto con licenciamiento permisivo y dependencias locales.

### 2.2.3. Generadores sin datos reales

Este segmento abarca sistemas generativos basados en la inyección de reglas y diccionarios estáticos, sin capacidades de entrenamiento empírico. Constituyen un componente funcional para poblar atributos semánticos tipificados, pero carecen de la exhaustividad necesaria para soluciones complejas.

#### Faker

Librería focalizada en la falsificación de entidades tipificadas: nomenclatura de personas, localizaciones geográficas, correos o teléfonos. Incluye soporte para regionalizaciones (`es_AR`, `es_MX`, careciendo de `es_UY`). Licenciada bajo MIT y soportada en múltiples lenguajes (Proyecto Faker, 2025). No extrae información de distribuciones subyacentes. Opera habitualmente como la capa subyacente para herramientas de orquestación complejas.

#### Mockaroo

Plataforma en formato SaaS (con variantes *on-premise*) enfocada en la construcción paramétrica de esquemas. Cubre más de 150 dominios de datos predefinidos e integra lógica condicional básica. Su enfoque manual lo relega fundamentalmente a fases de prototipado.

#### Tonic Fabricate y NVIDIA NeMo Data Designer

Representan la modernización de los generadores estáticos: integran orquestación estadística acoplada al esquema relacional y admiten inferencia vía Modelos de Lenguaje Grande (LLMs) para columnas de texto libre (NVIDIA, 2025). NeMo Data Designer mantiene naturaleza *Open Source*, no obstante, su orientación primaria radica en la estructuración de *datasets* para investigación en IA, divergiendo de los requerimientos de migración de bases transaccionales.

### 2.2.4. Anonimizadores a nivel de motor de base de datos

#### PostgreSQL Anonymizer

Extensión madura de código abierto, desarrollada por Dalibo y licenciada bajo PostgreSQL. La versión actual relevada es la 2.2 (Dalibo, 2025).

**Modelo de uso declarativo.** La parametrización se define semánticamente a través del `SECURITY LABEL` sobre las entidades DDL:

```
CREATE EXTENSION IF NOT EXISTS anon CASCADE;

SECURITY LABEL FOR anon ON COLUMN cliente.apellido
  IS 'MASKED WITH FUNCTION anon.fake_last_name()';

SECURITY LABEL FOR anon ON COLUMN cliente.telefono
  IS 'MASKED WITH FUNCTION anon.partial(telefono, 2, $$******$$, 2)';

SECURITY LABEL FOR anon ON COLUMN cliente.fecha_nac
  IS 'MASKED WITH VALUE NULL';
```

Esta aproximación otorga un beneficio directo de trazabilidad, permitiendo el control de versiones de las directivas de anonimización en sincronía con el esquema de base de datos.

**Estrategias de aplicación.** La herramienta faculta distintos canales de inyección, detallados en la Tabla 2.6, destacándose el despliegue mediante volcados estáticos para los fines de esta tesis.

| **Estrategia** | **Qué hace** | **Caso de uso** |
|---|---|---|
| *Anonymous Dumps* | Exporta los datos enmascarados a un archivo SQL | El caso central del proyecto: generar el volcado que puebla preproducción |
| *Static Masking* | Destruye permanentemente los datos originales en la base | Para una copia intermedia ya aislada |
| *Dynamic Masking* | Oculta el dato solo para roles marcados | Producción con acceso de soporte |
| *Masking Views* | Vistas enmascaradas | Acceso analítico |
| *Masking Data Wrappers* | *Foreign data wrappers* enmascarados | Federación |
| *Replica Masking* | Enmascarado sobre una réplica | Aislamiento de carga |

Tabla 2.6: Estrategias de aplicación de PostgreSQL Anonymizer

**Funcionalidades y limitaciones**: Incluye algoritmos de sustitución, seudonimización, adición de ruido sintético y borrado seguro, satisfaciendo el catálogo normativo determinista. Sin embargo, su operación se restringe al ecosistema PostgreSQL, adolece de preservación de distribuciones conjuntas y no provee mecanismos intrínsecos de consistencia multi-tabla fuera de los hashes estáticos deterministas.

#### Funcionalidades nativas de los motores

La gran mayoría de los RDBMS empresariales incluyen módulos propios de enmascaramiento. Sin embargo, su utilidad suele limitarse a la contención de brechas internas y no a migraciones de estado.

| **Motor** | **Función** | **Apto para preproducción** |
|---|---|---|
| SQL Server / Azure SQL | *Dynamic Data Masking* (2016+) (Microsoft, 2025a) | No. Enmascara solo en tiempo de consulta y no persiste al copiar o exportar la base. Un usuario con permisos *ad hoc* puede eludirlo. No funciona en *joins* entre bases sobre columnas enmascaradas ni con vistas indexadas. Está diseñado para limitar la exposición en producción. |
| SQL Server | *Static Data Masking* | Se introdujo como funcionalidad preliminar en SSMS 18 y nunca alcanzó la madurez de las alternativas de terceros. Verificar disponibilidad en la versión concreta. |
| Oracle | *Data Masking and Subsetting Pack* | Sí, pero es un paquete licenciado aparte de Enterprise Edition, con costo relevante. |
| MySQL | *Data Masking Component* | Solo en MySQL Enterprise Edition. |
| PostgreSQL | Ninguna nativa | Se cubre con la extensión anterior. |

Tabla 2.7: Enmascarado nativo de los motores y su aptitud para preproducción

Estos datos verifican que el enmascaramiento dinámico (nativamente provisto por los motores) opera como un agente en la capa de seguridad de roles, mas no como un motor de persistencia transaccional apto para flujos CI/CD de preproducción.

### 2.2.5. Anonimización formal: ARX

ARX Data Anonymization Tool (Prasser y Kohlmayer, 2025) se posiciona como un referente en auditoría y aplicación de garantías estadísticas formales bajo licencia Apache 2.0.

Implementa modelos de métrica sintáctica (modelos orientados a agrupamiento como $k$-anonimato, $\ell$-diversidad, $t$-cercanía) y semántica (privacidad diferencial y límites heurísticos). Provee métodos de generalización topográfica, microagregación y supresión escalar de variables.

Su aplicabilidad directa sobre esquemas transaccionales se ve severamente limitada por la dimensionalidad: está diseñado para tablas planas únicas. La aplicación forzada de algoritmos como el $k$-anonimato sobre entidades altamente vinculadas desintegra el valor operacional de la data, tal y como lo documentan agencias reguladoras como el ICO (Information Commissioner's Office,

2025). En el contexto de este diseño, ARX funge eficientemente como módulo de validación terminal sobre proyecciones analíticas del volumen.

### 2.2.6. Suites comerciales de gestión de datos de prueba

#### Tonic.ai

Suite modular (Tonic.ai, 2026) segmentada en soluciones estructurales, de textos libres y orquestación de clústeres efímeros.

Su capacidad técnica más distintiva es el analizador de subgrafos (*subsetter*). Este motor navega el árbol de dependencias a partir de tablas raíz, detectando dependencias cíclicas, proponiendo extrapolaciones virtuales para *joins* no declarados y preservando tablas paramétricas catálogadas. Este proceso computa en concurrencia con los pipelines generativos o de enmascaramiento. Ofrece gran flexibilidad inter-motor y mecanismos de alerta para disrupciones de estructura.

#### Perforce Delphix

Infraestructura integral (Perforce, 2026) focalizada primordialmente en virtualización.

El diferencial de la plataforma recae en su manejo volumétrico: genera clones virtuales de bases completas consumiendo una fracción marginal de almacenamiento subyacente. Acoplado a esto, posee módulos de detección y cumplimiento para anonimizar el *stream* de clonación. Requiere grandes inversiones corporativas (reportes sugieren niveles de USD 370.000 de mantenimiento anual) y demanda configuraciones complejas para mitigar problemas de IOPS en instancias de múltiple terabyte.

#### Otros actores

El espectro corporativo se completa con plataformas como Informatica TDM, Broadcom Test Data Manager e IBM Optim.

En síntesis, estas herramientas demuestran altísimos estándares de madurez industrial y operan con eficacia comprobada, pero su adopción en investigaciones académicas presenta obstáculos infranqueables: opacidad en los motores de generación probabilística, costos restrictivos y arquitecturas cerradas que impiden la inyección de validadores propios. Se consolidan como un umbral de funcionalidad aspiracional.

### 2.2.7. Librerías de síntesis tabular

#### SDV — Synthetic Data Vault

Desarrollada originariamente en MIT y mantenida bajo la entidad DataCebo (DataCebo, 2025; Patki, Wedge, y Veeramachaneni, 2016). Comprende una plétora de submódulos enfocados en la fidelidad probabilística.

| Librería | Función | Licencia |
|---|---|---|
| `sdv` | Framework unificado: tabla única, multi-tabla, secuencial | BSL v1.1 |
| `copulas` | Métodos estadísticos clásicos (cópulas multivariadas) | BSL v1.1 |
| `ctgan` | CTGAN y TVAE | BSL v1.1 |
| `deepecho` | Series temporales | BSL v1.1 |
| `rdt` | *Reversible Data Transforms* | BSL v1.1 |
| `sdmetrics` | Evaluación de calidad y privacidad | MIT |
| `sdgym` | *Benchmarking* de generadores | BSL v1.1 |

Tabla 2.8: Componentes del ecosistema SDV y sus licencias

Respecto a su integración comercial, la licencia BSL v1.1 permite la implementación en investigación académica y prototipado sin fricción, pero demanda auditoría para transiciones comerciales. Su módulo evaluativo, SDMetrics, se sustenta bajo licencia MIT pura, dotándolo de viabilidad íntegra para el proyecto.

Un diferenciador notorio de SDV es su gestor de invariantes lógicos (*constraints*), que fuerza a los algoritmos generativos a satisfacer aserciones relacionales. Por otro lado, un cuello de botella crítico documentado en la literatura radica en el módulo `HMASynthesizer`, cuya ineficiencia en búsquedas recursivas para validación de claves restringe la arquitectura a un máximo empírico de cinco entidades relacionales con saltos mínimos de profundidad (Autores de SyntheRela, 2024).

### MOSTLY AI Synthetic Data SDK

Presentado como un SDK distribuible a nivel industrial (MOSTLY AI, 2025b, 2025a). Su filosofía estructural prioriza la generación mediante una arquitectura autorregresiva de capas paralelas TabularARGN (Tiwald y cols., 2025). Este método omite el paradigma generalizado de decodificación por bloque de *transformers*, enfocándose en optimización tabular estricta.

```
pip install -U 'mostlyai[local]'

from mostlyai.sdk import MostlyAI
mostly = MostlyAI()                          # modo LOCAL: nada sale del entorno
g = mostly.train(data="/ruta/a/datos")       # entrena el generador
g.reports(display=True)                      # reporte de calidad y privacidad
mostly.probe(g, size=1_000_000)              # genera el volumen necesario
mostly.probe(g, seed=[{'edad': 65, 'genero': 'M'}])   # muestreo condicionado
g.export_to_file()                           # el generador es portable
```

La aptitud técnica de MOSTLY AI para el proyecto emana de su licenciamiento libre de restricciones productivas (Apache 2.0), su aislamiento perimetral explícito (`modo LOCAL`) y la estandarización nativa del método DP-SGD para perturbación gradiente de ruido diferencial. Especial mención requiere su empaquetamiento final: el artefacto de síntesis entrenado se persiste localmente permitiendo trazabilidad y reconstrucción de estados generativos exactos. Sus

áreas de mejora relativas a validación multi-tabla requieren instrumentación suplementaria.

#### Otras librerías relevantes

Para completar el ecosistema académico de síntesis, la Tabla 2.9 resume proyectos secundarios de alta validez técnica.

| **Librería** | **Licencia** | **Aporte** |
|---|---|---|
| synthcity (van der Schaar Lab, 2025) | Apache 2.0 | Implementaciones unificadas de un catálogo amplio de generadores; útil para comparativas |
| SyntheRela (Autores de SyntheRela, 2024) | MIT | *Benchmark* específico de bases relacionales sintéticas: fidelidad de columna, de tabla y multi-tabla, con métricas de similitud de cardinalidad y de correlación a $k$ saltos. Directamente aplicable al proyecto |
| SynthEval (Lautrup y cols., 2025) | Código abierto | Framework unificado de evaluación de fidelidad, utilidad y privacidad |
| REaLTabFormer (Solatorio y Dupriez, 2023) | Código abierto | Transformer para estructura relacional entre tablas |
| ClavaDDPM (Pang y cols., 2024) | Código abierto | Difusión guiada por agrupamientos para datos multi-relacionales, enfocada en restricciones de clave foránea |
| NeMo Safe Synthesizer | NVIDIA AI Enterprise | Síntesis con privacidad diferencial a partir de un conjunto semilla; requiere licencia comercial |

Tabla 2.9: Otras librerías de síntesis y evaluación relevadas

### 2.2.8. Detección de datos sensibles

Este eslabón orquesta el proceso de mapeo inicial, identificando los vectores de vulnerabilidad PII (*Personally Identifiable Information*).

#### Microsoft Presidio

Línea base determinista de la industria, liberada por Microsoft bajo MIT (Microsoft, 2025b). Amalgama librerías NER (spaCy), heurística regular y esquemas de validación modular por comprobaciones lógicas (*checksums*). El módulo `presidio-structured` proporciona integración directa con representaciones matriciales (pandas/Spark). Su falencia inherente radica en la incapacidad de analizar contextos holísticos de metadatos, evaluando series de manera completamente aislada.

#### GLiNER y GLiNER2-PII

Redes especializadas (Zaratiana y cols., 2026) de bajo espectro paramétrico (inferiores a los 500M de parámetros). Han demostrado gran eficacia mediante su ejecución local en procesadores convencionales (CPU), obteniendo métricas comparables a LLMs de gran envergadura. Su reciente versión (GLiNER2-PII) se orienta a 42 tipologías taxonómicas de PII distribuidas transversalmente (banca, gubernamental, contactos).

#### Modelos de lenguaje con contexto de esquema

La iteración de este campo hacia la contextualización ha aportado un avance sustancial. El estudio empírico condensado en la Tabla 2.10 evidencia la superioridad analítica al integrar semántica adyacente (Agisha Ntwali, Rück, y Heckmann, 2025).

| Conjunto de datos | Métrica | Presidio | CASSED | LLM con contexto |
|---|---|---|---|---|
| DeSSI (sintético, 6.272 columnas) | Macro F1 | 0,793 | **0,996** | 0,766 |
| Kaggle (13 conjuntos reales) | Macro F1 | 0,293 | 0,349 | **0,902** |
| OpenML (20 conjuntos reales) | Macro F1 | 0,684 | 0,501 | **0,964** |
| MIMIC-Demo-Ext (clínico real) | Macro F1 | 0,662 | 0,724 | **0,829** |
| **Promedio** | Macro F1 | 0,608 | 0,643 | **0,865** |

Tabla 2.10: Comparación de enfoques de detección de datos personales en datos estructurados (Agisha Ntwali y cols., 2025)

Al alimentar a un LLM no solo con inferencias fila por fila, sino proveyendo el diccionario de metadatos relacional y la intencionalidad del esquema, el modelo puede deducir la sensibilidad de campos ofuscados por ambigüedad. Como referencia práctica, atributos genéricos como `Ticket` en bases de reservas se clasifican correctamente como PII mediante abstracción contextual, un análisis imposible para reglas estáticas (Presidio).

No obstante, esta técnica de vanguardia genera externalidades a evaluar: alto índice de error Tipo II (falsos negativos), exigencias computacionales severas y posibles rupturas de cumplimiento normativo si el contexto del esquema interactúa con una red neuronal de un proveedor alojado fuera de los límites de soberanía del dato.

### 2.2.9. Validación y evaluación

La cuantificación de calidad estadística y nivel de fuga de información exige separación estricta de las etapas generativas.

#### Anonymeter

Solución arquitectónica propuesta por la comunidad académica (Giomi, Boenisch, Wehmeyer, y Tasnádi, 2023) orientada a instrumentalizar las tres aristas dictaminadas en la normativa europea WP216 (aislamiento, inferencia y vinculación cruzada).

La base del testeo consiste en ejecutar simulaciones de ataque adversarial tripartito. Un atacante *naive* interactuando con datos generados aleatoriamente; un atacante control operando sobre registros de retención (*holdout dataset*) aislados del proceso generativo; y un atacante principal correlacionando la síntesis final con vectores exógenos. La inferencia de la seguridad se delimita mediante el éxito marginal del atacante principal respecto a los otros dos baselines.

#### SDMetrics

Módulo de *benchmark* estadístico que expone índices correlacionales a través de medidas estandarizadas (test KS, distancia de varianza) y conservación de simetría de distribución marginal.

#### SyntheRela

Componente emergente en la validación referencial multivariada (Autores de SyntheRela, 2024). Implementa cuantificaciones específicas para ecosistemas padre-hijo, midiendo el desvío de cardinalidades (*cardinality similarity*) y la pérdida entrópica a *k-saltos* de distancia en grafos relacionados.

#### Métricas complementarias

| **Métrica** | **Qué mide** | **Precaución** |
|---|---|---|
| DCR (*Distance to Closest Record*) | Distancia de cada registro sintético al registro real más cercano | Solo es informativo comparado contra un conjunto retenido. Un DCR bajo en términos absolutos no dice nada; uno sistemáticamente menor que el del conjunto retenido indica sobreajuste |
| NNDR (*Nearest Neighbor Distance Ratio*) | Razón entre la distancia al primer y al segundo vecino | Complementa a DCR |
| Inferencia de membresía | Si se puede determinar que un registro estuvo en el entrenamiento | El ataque más directo y más citado en la literatura |
| Inferencia de atributos | Si se puede inferir un atributo sensible conociendo los demás | Equivalente al evaluador de inferencia de Anonymeter |
| Coincidencias exactas | Cantidad de filas sintéticas idénticas a filas reales | Verificación mínima obligatoria; debería ser cero |
| $k$-anonimato del resultado | Tamaño del grupo de equivalencia mínimo | Métrica sintáctica, complementaria; se obtiene con ARX |
| $\varepsilon$ (privacidad diferencial) | Garantía formal de indistinguibilidad | Solo aplicable si el generador usa DP-SGD |

Tabla 2.11: Métricas complementarias de riesgo de privacidad

### 2.2.10. Rol de la inteligencia artificial en el proceso

Es imperativo diferenciar funcionalmente las iteraciones metodológicas basadas en modelos de lenguaje.

La evidencia empírica respalda el uso de modelos de lenguaje para tareas de **clasificación contextualizada**, mejorando de manera notoria la extracción semántica y reduciendo la tasa de falsos positivos en entidades difusas.

Por el contrario, los estudios contemporáneos cuestionan severamente su viabilidad para la **generación directa de volumen** en formato tabular. Los costos de inferencia paralela para millones de tokens son irracionales económicamente, y la tendencia heurística de las redes LLM rompe invariablemente consistencias

matemáticas simples o retiene fragmentos verídicos de entrenamiento (European Data Protection Board, 2026).

El vector de desarrollo más prometedor recae en la **orquestación estricta y compilación analítica**. Utilizar LLMs para interpretar catálogos semánticos, deducir relaciones implícitas y parametrizar un archivo formal (JSON, YAML) que será ingerido por un agente generativo determinístico, limita el vector de ataque a los metadatos y excluye a las alucinaciones probabilísticas de comprometer los registros tabulares transaccionales.

## 2.3. Matrices de comparación técnica

### 2.3.1. Costos y licenciamiento

| **Herramienta** | **Licencia** | **Costo** | **Uso prod.** | **Riesgo de continuidad** |
|---|---|---|---|---|
| MOSTLY AI SDK | Apache 2.0 | Gratis | Sí | Medio (marca adquirida en 2026; la licencia otorgada es irrevocable) |
| SDV Community | BSL v1.1 | Gratis | Restringido | Bajo |
| SDMetrics | MIT | Gratis | Sí | Bajo |
| Anonymeter | BSD Clear | Gratis | Sí | Bajo (estable, poca actividad) |
| SyntheRela | MIT | Gratis | Sí | Medio (proyecto académico) |
| PostgreSQL Anonymizer | Licencia PostgreSQL | Gratis | Sí | Bajo (mantenido por Dalibo) |
| ARX | Apache 2.0 | Gratis | Sí | Bajo (13+ años) |
| Presidio | MIT | Gratis | Sí | Bajo (Microsoft) |
| GLiNER | Apache 2.0 (varía por modelo) | Gratis | Sí | Bajo |
| Faker | MIT | Gratis | Sí | Bajo |
| SDV Enterprise | Comercial | Cotización | Sí | Bajo |
| Tonic.ai | Comercial | Anual, por volumen de datos fuente | Sí | Bajo |
| Perforce Delphix | Comercial | Orden de USD 370K/año reportado | Sí | Bajo |
| NeMo Data Designer | Código abierto | Gratis (el microservicio requiere licencia) | Sí | Bajo |
| NeMo Safe Synthesizer | NVIDIA AI Enterprise | Cotización | Sí | Bajo |
| Mockaroo | Comercial/freemium | Suscripción | Sí | Bajo |
| Gretel.ai | — | — | — | Descontinuado como producto independiente |

Tabla 2.12: Costos, licenciamiento y riesgo de continuidad

### 2.3.2. Productividad y eficiencia

La restricción de aceleración matricial (hardware GPU) limita la implementación a algoritmos ensamblados por árboles de decisión o variantes optimizadas de ARGN, dejando relegadas arquitecturas avanzadas de difusión.

| **Enfoque** | **Setup** | **Entrenamiento** | **Tasa de generación** | **Recursos** |
|---|---|---|---|---|
| Faker / reglas | Minutos por columna | N/A | Muy alta | CPU mínimo |
| PostgreSQL Anonymizer | Horas (definir reglas) | N/A | Alta | CPU, en el motor |
| ARX ($k$-anonimato) | Horas (jerarquías) | N/A | Media | CPU |
| GaussianCopula (SDV) | Minutos | Segundos a minutos | Alta | CPU |
| Árboles (ARF, XGBoost) | Minutos | Minutos | Alta | CPU |
| TabularARGN | Minutos | Minutos | Alta | CPU o GPU |
| CTGAN / TVAE | Minutos | Decenas de minutos a horas | Media | GPU recomendada |
| TabDDPM / difusión | Minutos | Horas | Baja (muestreo iterativo) | GPU necesaria |
| LLM generando filas | Minutos | N/A o ajuste costoso | Muy baja | GPU o API de pago |

Tabla 2.13: Productividad y eficiencia computacional por enfoque

| **Herramienta** | **On-premise** | **Modelo** |
|---|---|---|
| MOSTLY AI SDK | Sí | Modo LOCAL explícito: entrenamiento y generación en el entorno propio |
| SDV (Community y Enterprise) | Sí | SDK Python instalable, sin servicio hospedado |
| PostgreSQL Anonymizer | Sí | Corre dentro del motor: el dato nunca sale de PostgreSQL |
| ARX | Sí | Aplicación de escritorio Java más API |
| Presidio / GLiNER | Sí | Librerías locales; GLiNER corre en CPU |
| Tonic.ai | Parcial | El agente corre en el perímetro del cliente; el plano de control es SaaS |
| Perforce Delphix | Sí | *Appliances* y máquinas virtuales propias, con soporte de Kubernetes |
| NeMo Safe Synthesizer | Sí | Microservicio desplegable; requiere licencia comercial |
| Mockaroo | Parcial | Versión autohospedada de pago |
| APIs de modelos comerciales | No | Por definición |
| Modelos pequeños locales | Sí | Vía Ollama, vLLM o llama.cpp |

Tabla 2.14: Capacidad de despliegue dentro del perímetro propio

### 2.3.3. Despliegue dentro del perímetro propio

### 2.3.4. Parametrización y control

La parametrización de restricciones de negocio constituye el área donde las herramientas de código abierto presentan mayores limitaciones funcionales respecto a las alternativas comerciales. Diseñar un mediador o capa orquestadora para solucionar estos puntos ciegos se define como un área fértil para innovaciones académicas.

| Herramienta | Reglas de negocio | Ajuste de distribuciones | Restricciones duras | Muestreo condicionado |
|---|---|---|---|---|
| PostgreSQL Anonymizer | Funciones propias en SQL/PLpgSQL | No | Por construcción (preserva el esquema) | N/A |
| ARX | Jerarquías de generalización | Vía parámetros de privacidad | Garantías formales ($k$, $\ell$, $t$, $\varepsilon$) | No |
| SDV Community | Sistema de restricciones lógicas | Metadatos y transformadores | Parcial | Sí |
| SDV Enterprise | Autodetección y restricciones multi-tabla | Sí | Fuerte | Sí (dirigido) |
| MOSTLY AI SDK | Configuración del generador, DP configurable | Sí | Limitado | Sí (semilla de valores fijos) |
| Tonic Structural | Biblioteca de generadores, consistencia entre tablas | Sí | Sí | Vía *subsetting* |
| Delphix | Algoritmos de enmascarado configurables | Limitado | Integridad referencial garantizada | Vía *subsetting* |
| Faker / Mockaroo | Todo es regla | Manual | Manual | N/A |

Tabla 2.15: Parametrización y control sobre el resultado

### 2.3.5. Matriz consolidada de decisión

La Tabla 2.16 expone una validación relacional unificada categorizando variables con una nomenclatura escalar: **A** alto, M medio, B bajo, – nulo o no aplica.

| Criterio | PG Anon. | ARX | SDV | MOSTLY | Tonic | Delphix | LLM solo |
|---|---|---|---|---|---|---|---|
| Costo (menor es mejor) | **A** | **A** | **A** | **A** | B | – | M |
| Libertad de licencia | **A** | **A** | M | **A** | – | – | M |
| On-premise / no exposición | **A** | **A** | **A** | **A** | M | **A** | – |
| Preserva distribuciones | – | B | **A** | **A** | M | M | B |
| Preserva integridad referencial | **A** | – | M | M | **A** | **A** | – |
| Multi-tabla / relacional | **A** | – | B | M | **A** | **A** | – |
| Eficiencia computacional | **A** | M | M | **A** | **A** | **A** | B |
| Parametrización / reglas | M | **A** | M | M | **A** | M | **A** |
| Métricas de privacidad integradas | – | **A** | M | **A** | M | B | – |
| Descubrimiento automático de PII | – | – | B | – | **A** | **A** | **A** |
| Auditabilidad / trazabilidad | **A** | **A** | M | M | M | M | B |
| Multi-motor de base de datos | – | M | M | M | **A** | **A** | **A** |
| Madurez / riesgo de continuidad | **A** | **A** | **A** | M | **A** | **A** | M |

Tabla 2.16: Matriz consolidada de decisión (**A** alto, M medio, B bajo, – nulo o no aplica)

| Motor | PG Anon. | Tonic | Delphix | SDV / MOSTLY | Notas |
|---|---|---|---|---|---|
| PostgreSQL | Sí | Sí | Sí | Sí | Mejor soportado del ecosistema de código abierto |
| MySQL / MariaDB | No | Sí | Sí | Sí | MySQL Enterprise tiene componente propio |
| Amazon Aurora | Parcial | Sí | Sí | Sí | La restricción de instalar extensiones propias es el principal obstáculo |
| SQL Server | No | Sí | Sí | Sí | El enmascarado dinámico nativo no sirve para preproducción |
| Oracle | No | Parcial | Sí | Sí | Solo nivel Enterprise en Tonic; el paquete nativo es alternativa licenciada |
| Db2 | No | Sí | Parcial | Sí | |
| SAP ASE | No | No | Sí | Sí | |

Tabla 2.17: Cobertura por motor de base de datos. SDV y MOSTLY AI operan sobre datos ya extraídos, por lo que son agnósticos al motor

### 2.3.6. Cobertura por motor de base de datos

## 2.4. El problema técnico central: preservar la integridad referencial

### 2.4.1. Claves primarias

La naturaleza intrínseca de una clave primaria inhibe la utilidad de generar distribuciones estadísticas asociadas. Emplear un motor generativo en columnas identificadoras desata una carencia inminente de unicidad y problemas de fragmentación. Las posibles vertientes para su abordaje se encuentran listadas en la Tabla 2.18.

| Estrategia | Cuándo usar | Problema |
|---|---|---|
| Regenerar secuencialmente | Claves subrogadas (SERIAL, IDENTITY) | Rompe cualquier clave foránea que apunte a ella, salvo que se propague el mapeo |
| Tokenización determinística | Claves naturales (cédula, RUT, correo) | Requiere mantener y proteger la tabla de mapeo, que es la "información adicional" que hace reversible la seudonimización |
| Hash con sal | Claves naturales, sin necesidad de reversibilidad | Cuidado con el dominio chico: una cédula uruguaya es un espacio de búsqueda trivialmente enumerable. Hashear sin una sal larga y secreta no es protección |
| Cifrado que preserva formato | Claves con formato validado por la aplicación | Requiere gestión de claves |

Tabla 2.18: Estrategias de tratamiento de claves primarias

### 2.4.2. Claves foráneas e integridad referencial

Los métodos predominantes para resolver esta consistencia se dividen en tres grandes filosofías.

**A. Preservación estática.** Sustituir la lógica de cardinalidad por replicación del esqueleto referencial intacto y generación probabilística de atributos. No obstante, si una entidad matriz se asocia a topologías muy atípicas, persiste un factor considerable de ataque inferencial (ej. un usuario con órdenes exponenciales al percentil).

**B. Síntesis relacional exhaustiva.** Las topologías de difusión y métodos recursivos como ClavaDDPM intentan inferir conjuntamente atributos y uniones referenciales (Autores de SyntheRela, 2024). Los informes refutan la escalabilidad de este diseño a bases de datos masivas.

**C. Arquitectura híbrida.** Constituye el balance propuesto. Estructuración determinista de dependencias, acoplado a un proceso de remuestreo probabilístico de varianzas y *outliers* referenciales. Logra acortar las debilidades del método A sin recurrir a la incertidumbre escalar del método B.

### 2.4.3. Extracción de subconjuntos con integridad referencial

Las principales dificultades técnicas radican en las dependencias referenciales programáticas que residen a nivel de código de backend y no están normalizadas en la base (falsos nexos referenciales). Asimismo, las referencias polimórficas (uniones que apuntan condicionalmente a entidades distintas) desafían cualquier generador de código abierto, produciendo cascadas imprevisibles en el muestreo de datos aislados.

### 2.4.4. Tipos de datos complejos

## 2.5. Criterios de evaluación

### 2.5.1. Un dato sintético no es un dato anónimo

Es imperativo destacar, para evitar un error conceptual recurrente en la industria, que un conjunto de datos sintéticos retiene su estatus inherente de dato personal hasta probar su disociación estadística total a posteriori. Basando esta premisa en las directrices de revisión 2026 de EDPB (European Data Protection Board, 2026), un volumen que es fiel en excesivo grado a su origen sacrifica inexorablemente su impenetrabilidad, exponiendo al algoritmo a vulnerabilidades por inferencia analítica (Giomi y cols., 2023).

| Tipo | Comportamiento típico | Recomendación |
|---|---|---|
| JSON / JSONB, ARRAY, XML | Mal soportados por los sintetizadores tabulares; se tratan como cadena opaca | Extraer campos relevantes a columnas, procesar y reensamblar, o aplicar reglas deterministas sobre las claves conocidas |
| Geoespaciales | No soportados | Generalización espacial: reducir la precisión de las coordenadas |
| BLOB / BYTEA | Ignorados o pasados sin cambios | Riesgo alto: pueden contener documentos con datos personales. Reemplazo por un archivo de relleno del mismo tamaño |
| Texto libre | Tratado como categórica de alta cardinalidad, con malos resultados | Proceso separado: reconocimiento de entidades (Presidio o GLiNER) y redacción, o síntesis textual |
| ENUM / dominios | Bien soportados como categóricas | Verificar que el sintetizador no genere valores fuera del dominio |
| Temporales | Soportados, pero se pierde la coherencia entre fechas relacionadas | Restricción explícita del tipo fecha de baja posterior a fecha de alta |
| Columnas cifradas | No procesables | Documentar y excluir |
| Columnas computadas | Deben recalcularse, no sintetizarse | Excluir de la síntesis y recalcular al cargar |

Tabla 2.19: Tratamiento de tipos de datos complejos

### 2.5.2. Utilidad para testing frente a utilidad para aprendizaje automático

Las validaciones genéricas aplicables a Machine Learning difieren dramáticamente a las exigidas en los ciclos QA (*Quality Assurance*) de software. La evaluación se dimensiona de forma distinta, documentada en la Tabla 2.20.

| Dimensión | Qué mide | Cómo medirla |
|---|---|---|
| Validez estructural | ¿La base carga? ¿Las claves foráneas resuelven? ¿Las restricciones CHECK se satisfacen? | Binario: la carga completa sin errores |
| Validez de formato | ¿Los valores pasan las validaciones de la aplicación? | Ejecutar los validadores de la aplicación sobre el conjunto de datos |
| Cobertura funcional | ¿La suite de pruebas existente pasa? ¿Con qué cobertura de código? | Correr la suite y comparar cobertura contra el ambiente con datos reales |
| Cobertura de casos borde | ¿Están representados los valores nulos, vacíos, extremos, con caracteres especiales o de longitud máxima? | Perfilado comparativo: para cada columna, si el sintético cubre las mismas clases de equivalencia que el real |
| Reproducción de errores | ¿Los errores reportados en producción se reproducen? | Métrica de referencia, difícil de operacionalizar; se aproxima con casos derivados de incidentes históricos |
| Realismo de volumen | ¿Las consultas tienen planes de ejecución comparables? | Comparar planes de ejecución y estadísticas del optimizador entre ambientes |
| Distribución de cardinalidades | ¿Un cliente promedio tiene una cantidad realista de pedidos? | Comparar distribuciones de cardinalidad padre-hijo |

Tabla 2.20: Dimensiones de utilidad para testing de software

La carencia de volumen representativo en preproducción ocasiona una anomalía recurrente e imperceptible durante la ejecución: la pérdida de fidelidad en la planificación del motor de consultas.

### 2.5.3. Privacidad diferencial: qué garantiza y qué no

Resulta fundamental precisar este concepto, dado que suele interpretarse de forma errónea en la práctica. La inyección de ruido o el empleo de algoritmos calibrados (*Differential Privacy SGD* en modelos como DP-CTGAN) (Ponomareva y cols., 2025) operan como un método analítico que permite acotar el riesgo, pero no confieren un certificado unívoco de anonimato, tal como explicita el ICO (Information Commissioner's Office, 2023). Resulta imperativo gestionar con diligencia la métrica acumulativa ($\varepsilon$) resultante de refinamientos repetitivos para asegurar su legitimidad normativa en el tiempo.

# Capítulo 3

# Arquitectura de referencia y pila tecnológica propuestas

Este capítulo presenta la propuesta preliminar derivada del relevamiento bibliográfico y funcional. El diseño detallado, especificación de requerimientos y despliegue final quedan proyectados para las etapas posteriores de este trabajo de tesis.

## 3.1. Por qué la orquestación es necesaria

Teniendo presente los resultados de la Sección 2.2.1, resulta evidente la ausencia de una alternativa unificada que cubra el espectro completo sin adolecer de licencias restrictivas o limitantes de opacidad matemática. Ante esto, el factor neurálgico del proyecto asume la necesidad de erigir una arquitectura multiagente u orquestadora que consolide las virtudes aisladas de los proyectos *open source* vigentes.

## 3.2. Arquitectura de referencia por capas

**Capa 0 — Introspección.** Análisis del esquema interno `information_schema`. Garantiza la recopilación fidedigna de interrelaciones.

**Capa 1 — Clasificación asistida.** Secuencia híbrida: cotejo por reglas deterministas (Presidio), modelos ligeros PII (GLiNER) e inspección contextual residual delegada a agentes conversacionales de lenguaje, finalizando con un artefacto persistido.

**Capa 2 — Extracción.** Navegación selectiva y recursiva partiendo de una

matriz de entidades ancla para poblar un sub-esquema analítico con coherencia posicional.

**Capa 3 — Transformación.** Segmentación ejecutiva. Hashes para llaves y algoritmos estocásticos para los dominios semánticos de negocio. Validación dinámica en tiempo de muestreo garantizando la no vulneración de las lógicas estructurales de la base receptora.

**Capa 4 — Validación.** Evaluación transversal ajena al ente generador mediante un set formal de métricas estadísticas (SDMetrics, SyntheRela), integridad referencial y distancia frente a *hold-outs* (Anonymeter).

**Capa 5 — Trazabilidad.** Firmado en un manifiesto que aglomere hiperparámetros, esquemas, catálogos resultantes y niveles de ruido aplicados, logrando una estandarización trazable (alineada a GDPR/URCDP).

## 3.3. Consideraciones de implementación

**Paralelismo.** La ejecución asíncrona aplicará con efectividad para los mapeos sintéticos independientes, mientras que las rutinas extractivas sufrirán tiempos muertos derivados de dependencias acopladas en grafo.

**Invocación de funciones como contrato.** Las interacciones con LLMs quedan circunscriptas a validación de JSON schemas y parámetros predefinidos, invalidando su actuación como promotores de inyección SQL no auditables en la fuente original.

**Idempotencia y determinismo.** La varianza inherente en la generación de lenguaje exige congelar en artefactos estáticos (caché de red) los juicios generados por estos algoritmos, reduciendo la recarga al mínimo vital durante migraciones cíclicas.

**Degradación elegante.** Incorporar estrategias de contingencia: frente a la degradación métrica del modelo de IA o falla de consistencia, aplicar esquemas de enmascaramiento clásico y evitar la disrupción en los pipelines logísticos CI/CD.

**Interruptor de privacidad.** Implementar detenciones obligatorias ante niveles inadmisibles de proximidad euclidiana o *singling out*, transformando el análisis de riesgo retrospectivo en una fase condicionante *pre-commit*.

## 3.4. Pila tecnológica candidata

## 3.5. Por qué esta combinación y no otra

**Acerca de Tonic o Delphix**: satisfacen el caso de uso industrial de extremo a extremo pero clausuran cualquier viabilidad para desarrollo académico, en función de su opacidad integral y cuotas de mantenimiento estratosféricas.

| Capa | Herramienta candidata | Alternativa | Justificación |
|---|---|---|---|
| Introspección | `information_schema` y catálogos nativos | — | Determinista, portable, sin dependencias |
| Clasificación (reglas) | Microsoft Presidio (MIT) | Expresiones regulares propias | Alta precisión, sumas de verificación, extensible |
| Clasificación (NER local) | GLiNER / GLiNER2-PII | spaCy NER | Corre en CPU, menos de 500M de parámetros, cobertura amplia de tipos |
| Clasificación (contexto) | Modelo de lenguaje pequeño local con invocación de funciones | API comercial si el marco legal lo permite | El aporte de contexto es la diferencia entre 0,61 y 0,87 de macro F1. Local por cumplimiento |
| Extracción | Implementación propia sobre el grafo de claves foráneas | Tonic (línea base) | No hay implementación de código abierto madura; es un componente a construir |
| Enmascaramiento determinista | PostgreSQL Anonymizer si el destino es PostgreSQL | Faker más tokenización propia | Declarativo, versionable, dentro del motor, catálogo completo de funciones |
| Síntesis generativa | MOSTLY AI SDK / TabularARGN | SDV Community | Licencia plena, modo local, privacidad diferencial incorporada, eficiencia, generador exportable |
| Restricciones de negocio | Capa propia de validación y remuestreo | Restricciones de SDV | El hueco más claro del código abierto; espacio de aporte |
| Fidelidad | SDMetrics (MIT) | SynthEval | Licencia MIT, maduro, estándar de facto |
| Fidelidad relacional | SyntheRela (MIT) | — | Único con métricas multi-tabla |
| Privacidad | Anonymeter (BSD) | Implementación propia | Alineado con los tres criterios del WP216 y el EDPB, diseño de tres brazos |
| Anonimización formal | ARX (Apache 2.0) | — | Reporte de $k$-anonimato sobre tablas dimensionales |
| Orquestación | Python con invocación de funciones tipada | Airflow o Prefect para la planificación | El modelo propone, el sistema valida y ejecuta |

Tabla 3.1: Pila tecnológica candidata por capa

**Acerca de depender exclusivamente de SDV**: Representa el ecosistema predominante, pero su limitante severo recae sobre la inoperatividad demostrada del componente relacional `HMASynthesizer` ante arquitecturas distribuidas con dependencias cíclicas cruzadas en arquitecturas Fintech complejas.

**Acerca del uso aislado de LLM**: Carece de sentido computacional para transacciones masivas, y arrastra inconsistencias probabilísticas irreparables que invalidan las relaciones padre-hijo inherentes.

**Acerca del enmascaramiento determinista excluyente**: La elección más segura operativamente. No obstante, al cercenar la capacidad de extrapolar comportamientos emergentes (*edge cases*) y destruir las correlaciones subyacentes necesarias para el QA analítico profundo, recorta el mérito de una investigación científica moderna que excede a un simple script transaccional.

# Capítulo 4

# Diseño experimental y riesgos

En esta fase prematura, el capítulo condensa el plan empírico proyectado y enumera la mitigación de contingencias. La operacionalidad y métricas finales formarán parte integral de subsiguientes avances metodológicos.

## 4.1. Plan de validación

Se abordará mediante una división ortogonal de variables medibles dictaminada en la Capa 4 de la infraestructura. Esta conjuga evaluación referencial íntegra (ausencia de orfandad relacional), congruencia distributiva analizada vía *frameworks* formales (SDMetrics) y aplicabilidad directa en los tests de regresión perimetrales de una infraestructura en desarrollo, finalizando en los marcajes de control DCR sobre conjuntos intocados del *feed* inicial.

## 4.2. Riesgos residuales a documentar

| **Riesgo** | **Descripción** | **Mitigación** |
|---|---|---|
| Falso negativo de clasificación | Una columna con datos personales no se detecta y pasa sin protección | Cascada de detectores, revisión humana de los casos de baja confianza y sesgo hacia el falso positivo |
| Memorización del generador | El modelo reproduce registros reales | DCR contra conjunto retenido, coincidencias exactas y privacidad diferencial |
| Identificación estructural | La topología del grafo relacional identifica, aunque los atributos sean sintéticos | Remuestreo de cardinalidades y medición de *outliers* estructurales |
| Fuga por el modelo entrenado | El artefacto del generador contiene información del original y puede ser atacado | Tratar el generador como dato personal y controlar su acceso con los mismos criterios que el original |
| Fuga por la tabla de mapeo | La tabla de seudonimización revierte todo el proceso de una vez | Almacenamiento separado, cifrado, control de acceso, rotación de claves y registro de accesos |
| Acumulación de presupuesto de privacidad | Refrescos sucesivos del ambiente agotan $\varepsilon$ | Contabilidad explícita del presupuesto por conjunto de datos y ventana temporal |
| Deriva de esquema | El catálogo de clasificación queda desactualizado ante cambios en producción | Hash de esquema en el manifiesto y alerta ante divergencia |
| Envejecimiento del anonimato | Datos anónimos hoy pueden dejar de serlo | Reevaluación periódica, como recomienda el EDPB |
| Exposición vía el modelo de lenguaje | Metadatos o valores de muestra enviados a un tercero | Modelo local. Si se usa una API externa, enviar solo nombres de columnas, nunca valores |

Tabla 4.1: Riesgos residuales identificados y mitigaciones previstas

# Capítulo 5

# Conclusiones y trabajo futuro

## 5.1. Conclusiones del relevamiento

**1. Ausencia de una herramienta hegemónica de uso libre.** Si bien arquitecturas propietarias (Tonic, Delphix) exponen robustez en la extracción relacional y síntesis parametrizada, el ecosistema carece de un integrador de código abierto maduro, relegando su aplicación a flujos corporativos de presupuestos prohibitivos.

**2. Segmentación de las capacidades de las librerías gratuitas.** SDKs como MOSTLY AI o métricas como Anonymeter garantizan eficacia local sobre procesos específicos. La carencia crítica estriba en la identificación semántica inicial, convirtiendo a la arquitectura orquestadora en la principal vía para integrar dichas librerías.

**3. Contrastes funcionales en Modelos de Lenguaje.** La evidencia empírica respalda el uso de modelos de lenguaje para tareas de clasificación contextualizada (con métricas superiores a F1=0,85 en *datasets* crudos), pero cuestiona su viabilidad para la generación masiva de datos en comparación con motores deterministas robustos.

**4. Desmitificación de la infalibilidad en datos sintéticos.** Extrapolando directrices normativas aplicadas en 2026, la creación probabilística sin auditoría final es inexorable a ataques inferenciales, demandando controles transversales continuos en las tuberías de integración.

**5. Evolución del marco regulatorio.** Modificaciones directas sugeridas en el ámbito europeo tornan un reporte de evaluación de riesgo algorítmico en una exigencia jurídica y ya no en una mera buena praxis.

**6. Consolidación monopolística.** Alteraciones severas en el entorno empresarial durante el período analizado exhortan a priorizar un andamiaje orquestado sobre componentes que garanticen viabilidad de permanencia abierta e independiente.

**7. Vacíos técnicos identificados.** La síntesis compleja en bases hiperfragmentadas asoma como la principal dificultad actual para el estado del arte y un hito a mitigar por el proyecto en curso.

**8. Criterios dispares de validación funcional.** Medir el grado de asertividad requerida para entrenar un modelo estocástico no se extrapola orgánicamente para validar un plan de optimización DDL, evidenciando una falencia latente en las métricas especializadas al Testing puro.

## 5.2. Preguntas de investigación abiertas

El proceso deductivo decanta en cinco cuestionamientos focales que enmarcan la evolución empírica de la tesis.

1. ¿En qué proporción se incrementa la precisión taxonómica al proveer esquemas vinculantes y de negocio a un LLM local en contraste a heurísticas de mercado masivas?

2. ¿Cuáles serán las métricas idóneas para predecir eficientemente que las aserciones de integración regresiva culminen sin discrepancias operacionales en instancias transaccionales?

3. ¿Qué nivel de balanceo se manifiesta de manera real al ajustar presupuestos ($\varepsilon$) contra índices de aplicabilidad en los tests preexistentes del ecosistema subyacente?

4. ¿Bajo qué magnitudes la distribución bruta de nodos referenciales (grafos relacionales) es susceptible a *crawling* para identificación, omitiendo íntegramente las variables sensibles asociadas a ellos?

5. ¿Será técnica y lingüísticamente posible compilar la interpretación de lenguaje natural crudo hacia *pipelines* restrictivos forzados dentro de las métricas sintéticas?

## 5.3. Próximos pasos

Los hitos consiguientes delimitarán la estabilización conceptual detallada en el Capítulo 3, forzando la estrategia orquestada a validar los esquemas relacionales complejos con atributos determinísticos. Seguidamente se operará la arquitectura para refinar el sistema propuesto para QA, contrastando aserciones de regresión frente a métricas de privacidad estandarizadas.

Resulta prudente mencionar que los datos consolidados pertenecen al tercer cuatrimestre del 2026 y pueden estar sujetos a alteraciones dada la volatilidad inherente al sector tecnológico moderno.

# Referencias


Agisha Ntwali, A., Rück, L., y Heckmann, M. (2025). Detection of personal data in structured datasets using a large language model. En *Llm-dpm 2025.* (arXiv:2506.22305)

Article 29 Data Protection Working Party. (2014). *Opinion 05/2014 on anonymisation techniques (WP216).* Comisión Europea.

Autores de RelDiff. (2025). *RelDiff: Relational data generative modeling with graph-based diffusion models.* arXiv:2506.00710.

Autores de SyntheRela. (2024). *Benchmarking the fidelity and utility of synthetic relational data.* arXiv:2410.03411. https://github.com/martinjurkovic/syntherela.

Cai, K., Xiao, X., y Cormode, G. (2023). PrivLava: Synthesizing relational data with foreign keys under differential privacy. *Proceedings of the ACM on Management of Data (PACMMOD).*

Dalibo. (2025). *PostgreSQL Anonymizer: masking and anonymization extension for PostgreSQL.* https://postgresql-anonymizer.readthedocs.io/ · https://labs.dalibo.com/postgresql_anonymizer. (Versión 2.2. Consultado en setiembre de 2026)

DataCebo. (2025). *SDV: Synthetic Data Vault y SDMetrics.* https://sdv.dev · https://docs.sdv.dev. (Sobre el cambio de licencia: https://datacebo.com/blog/sdv-bsl-license/. Consultado en setiembre de 2026)

European Data Protection Board. (2026). *Guidelines 02/2026 on anonymisation.* Borrador para consulta pública, adoptado el 7 de julio de 2026. https://www.edpb.europa.eu/. (Consulta abierta hasta el 30 de octubre de 2026)

Giomi, M., Boenisch, F., Wehmeyer, C., y Tasnádi, B. (2023). A unified framework for quantifying privacy risk in synthetic data. *Proceedings on Privacy Enhancing Technologies (PoPETs).* (Anonymeter. arXiv:2211.10459. https://github.com/statice/anonymeter)

Information Commissioner's Office. (2023). *Privacy-enhancing technologies (PETs).* https://ico.org.uk/for-organisations/uk-gdpr-guidance-and-resources/data-sharing/privacy-enhancing-technologies/. (Consultado en setiembre de 2026)

Information Commissioner's Office. (2025). *Anonymisation.* https://ico.org.uk/for-organisations/uk-gdpr-guidance-and-resources/

data-sharing/anonymisation/. (Guía bajo revisión por la Data (Use and Access) Act. Consultado en setiembre de 2026)

Kotelnikov, A., Baranchuk, D., Rubachev, I., y Babenko, A. (2023). TabDDPM: Modelling tabular data with diffusion models. En *International conference on machine learning (icml)*.

Lautrup, A. D., y cols. (2025). SynthEval: A framework for detailed utility and privacy evaluation of tabular synthetic data. *Data Mining and Knowledge Discovery*, *39*(1).

Microsoft. (2025a). *Dynamic Data Masking (SQL Server)*. https://learn.microsoft.com/en-us/sql/relational-databases/security/dynamic-data-masking. (Consultado en setiembre de 2026)

Microsoft. (2025b). *Presidio: data protection and de-identification SDK*. https://github.com/microsoft/presidio. (Consultado en setiembre de 2026)

MOSTLY AI. (2025a). *Democratizing tabular data access with an open-source synthetic-data SDK*. arXiv:2508.00718.

MOSTLY AI. (2025b). *MOSTLY AI Synthetic Data SDK*. https://github.com/mostly-ai/mostlyai · https://mostly-ai.github.io/mostlyai/. (Consultado en setiembre de 2026)

NVIDIA. (2025). *NeMo Data Designer*. https://github.com/NVIDIA-NeMo/DataDesigner. (Consultado en setiembre de 2026)

Pang, W., y cols. (2024). ClavaDDPM: Multi-relational data synthesis with cluster-guided diffusion models. En *Advances in neural information processing systems (neurips)*. (arXiv:2405.17724)

Patki, N., Wedge, R., y Veeramachaneni, K. (2016). The Synthetic Data Vault. En *Ieee international conference on data science and advanced analytics (dsaa)*.

Perforce. (2026). *Perforce Delphix Data Platform*. https://www.perforce.com/products/delphix. (Consultado en setiembre de 2026)

Ponomareva, N., y cols. (2025). *How to DP-fy your data: A practical guide to generating synthetic data with differential privacy*. arXiv:2512.03238.

Prasser, F., y Kohlmayer, F. (2025). *ARX Data Anonymization Tool*. https://github.com/arx-deidentifier/arx. (Consultado en setiembre de 2026)

Proyecto Faker. (2025). *Faker: generación de datos falsos*. https://faker.readthedocs.io/. (Consultado en setiembre de 2026)

República Oriental del Uruguay. (2008). *Ley n.º 18.331 de Protección de Datos Personales y Acción de Habeas Data*. Diario Oficial. Complementada por el Decreto 414/009, el Decreto 64/020, la Ley 19.924 y la Ley 20.075.

Solatorio, A. V., y Dupriez, O. (2023). *REaLTabFormer: Generating realistic relational and tabular data using transformers*.

Tiwald, P., y cols. (2025). *TabularARGN: A flexible and efficient auto-regressive framework for generating high-fidelity synthetic data*. arXiv:2501.12012.

Tonic.ai. (2026). *Tonic.ai: test data management and synthesis platform*. https://www.tonic.ai/. (Consultado en setiembre de 2026)

URCDP. (2023). *Guía sobre Criterios de Disociación de Datos Personales*. Unidad Reguladora y de Control de Datos Personales, Uruguay. (Consultado

en setiembre de 2026)

van der Schaar Lab. (2025). *synthcity: a library for generating and evaluating synthetic tabular data.* https://github.com/vanderschaarlab/synthcity. (Consultado en setiembre de 2026)

Xu, L., Skoularidou, M., Cuesta-Infante, A., y Veeramachaneni, K. (2019). Modeling tabular data using conditional GAN. En *Advances in neural information processing systems (neurips).*

Zaratiana, U., y cols. (2026). *GLiNER, GLiNER2 y GLiNER2-PII: Generalist models for named entity recognition.* arXiv:2507.18546; arXiv:2605.09973.

Zhao, Z., Kunar, A., Birke, R., y Chen, L. Y. (2024). *CTAB-GAN y CTAB-GAN+: Effective table data synthesizing.*

# Anexo A

# Manifiesto de trazabilidad

Acorde a lo manifestado previamente sobre directrices evaluativas regulatorias, se anexa un marco logístico referencial en formato de metadato trazable, de suma importancia en caso de ser auditado para preproducción.

```
generacion:
  id: <uuid>
  timestamp: <fecha y hora>
  operador: <identidad>
origen:
  base: <identificador, nunca credenciales>
  esquema_hash: sha256:...          # detecta deriva de esquema
  snapshot: <punto en el tiempo>
  filas_por_tabla: {...}
clasificacion:
  version_catalogo: <version>
  metodo: [presidio, gliner, modelo-local]
  columnas_clasificadas: <n>
  revisadas_por_humano: <n>
  hash_catalogo: sha256:...
subsetting:
  tablas_ancla: [...]
  filtro: "..."
  porcentaje_resultante: <%>
  fk_virtuales_declaradas: [...]
  ciclos_resueltos: [...]
transformacion:
  determinista:
    columnas: <n>
    salt_id: <referencia a secreto, NUNCA el salt>
  generativa:
    modelo: <nombre>
```

```
    version: <x.y.z>
    semilla: <n>
    hiperparametros: {...}
    hash_generador: sha256:...
    dp: {habilitada: <bool>, epsilon: <e>, delta: <d>}
  restricciones_aplicadas: [...]
  filas_rechazadas_por_restriccion: <n>
validacion:
  integridad:   {fk_huerfanas: 0, pk_duplicadas: 0, check_violados: 0}
  fidelidad:    {column_shapes: ..., pair_trends: ...,
                 cardinalidad: ..., khop: ...}
  utilidad_testing: {suite_regresion: ..., cobertura_codigo: ...,
                     planes_ejecucion_divergentes: ...}
  privacidad:   {singling_out: ..., linkability: ..., inference: ...,
                 dcr_ratio_vs_holdout: ..., coincidencias_exactas: 0}
  gate: <APROBADO | RECHAZADO>
firma: <hash del manifiesto completo>
```

La viabilidad técnica radica en que, proveyendo semillas estadísticas homólogas con esquemas idénticos, la arquitectura devuelva *endpoints* generativos exactamente equitativos. Este aspecto elude la aleatoriedad natural del LLM congelando sus deducciones sobre *hasheos* catalogados permanentemente en el archivo maestro.