

UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY



FACULTAD DE
INGENIERÍA

Proceso asistido por inteligencia artificial para la extracción, anonimización y generación de bases de datos de preproducción para testing

Informe de avance: relevamiento del estado del arte

Informe de Proyecto de Grado presentado por

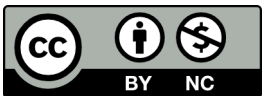
Jerónimo Jacques Balma y Virginia Paola Romay Bermúdez

en cumplimiento parcial de los requerimientos para la graduación de la carrera de Ingeniería en Computación de Facultad de Ingeniería de la Universidad de la República

Supervisor

Andrea Delgado

Montevideo, Setiembre de 2026



Proceso asistido por inteligencia artificial para la extracción, anonimización y generación de bases de datos de preproducción para testing

Informe de avance: relevamiento del estado del arte por Jerónimo Jacques Balma y Virginia Paola Romay Bermúdez tiene licencia CC Atribución - No Comercial 4.0.

Resumen

Este documento constituye un informe de avance de la primera etapa del Proyecto de Grado y presenta el estado del arte relevado hasta el momento. El proyecto busca diseñar un proceso asistido por inteligencia artificial que permita generar bases de datos de preproducción seguras y representativas para testing a partir de datos productivos, sin exponer información sensible.

El problema radica en balancear seguridad y utilidad. Usar una copia de producción maximiza el realismo a costa de un alto riesgo de exposición; generar datos enteramente ficticios elimina ese riesgo, pero pierde el rigor estadístico, la cardinalidad y los casos límite; y el enmascaramiento manual mediante scripts es frágil ante cambios de esquema y deficiente con los identificadores indirectos.

El relevamiento fija un vocabulario sobre las técnicas de protección de datos y su situación normativa, y revisa las técnicas de anonimización (como el k-anonimato), la privacidad diferencial y la generación de datos sintéticos mediante distintas familias de modelos generativos. Compara las herramientas disponibles según lo que hace cada una (generar datos, anonimizar, detectar datos sensibles, extraer subconjuntos y validar el resultado), su licencia y su posibilidad de ejecución local. Entre ellas se analizan PostgreSQL Anonymizer, ARX, Presidio, SDV y MOSTLY AI, además de las plataformas comerciales Tonic.ai y Delphix. Se revisa también en qué tareas la inteligencia artificial aporta evidencia favorable, el problema de preservar la integridad referencial y las dimensiones para evaluar una base de preproducción.

Del relevamiento surge que ninguna herramienta cubre sola el proceso completo con una licencia utilizable en este trabajo; que lo menos resuelto es decidir qué proteger y cómo, sobre todo en esquemas relacionales; que la evidencia favorece el uso de modelos de lenguaje para clasificar columnas sensibles y lo desfavorece para generar filas; y que la utilidad de una base para testing de software está poco cubierta por las herramientas y la literatura. Estos vacíos orientan la etapa siguiente del proyecto, dedicada a evaluar propuestas y definir una propia.

Palabras clave: Datos sintéticos, Anonimización, Datos de prueba, Integridad referencial, Privacidad

Índice general

1. Introducción **1**
- 1.1. Contexto y planteamiento del problema . . . 1
- 1.2. Objetivos de la etapa . . . 2
- 1.3. Resultados esperados . . . 2
- 1.4. Alcance de esta etapa . . . 3
- 1.5. Metodología del relevamiento . . . 3
- 1.6. Conclusiones principales . . . 4
- 1.7. Organización del documento . . . 4

2. Revisión de antecedentes **5**
- 2.1. Marco conceptual y regulatorio . . . 5
  - 2.1.1. Conceptos básicos . . . 5
  - 2.1.2. Taxonomía de técnicas de protección . . . 6
  - 2.1.3. Marco regulatorio aplicable . . . 7
- 2.2. Técnicas de protección de datos . . . 8
  - 2.2.1. Enmascaramiento y seudonimización . . . 8
  - 2.2.2. Modelos formales de anonimato . . . 8
  - 2.2.3. Privacidad diferencial . . . 9
  - 2.2.4. Otras tecnologías de mejora de la privacidad . . . 9
- 2.3. Generación de datos sintéticos . . . 10
  - 2.3.1. Datos inventados y datos aprendidos . . . 10
  - 2.3.2. Familias de modelos generativos tabulares . . . 10
  - 2.3.3. Riesgos de los datos sintéticos . . . 11
- 2.4. Relevamiento de herramientas . . . 12
  - 2.4.1. Criterios de organización . . . 12
  - 2.4.2. Plataformas comerciales integrales . . . 14
  - 2.4.3. Anonimización a nivel de motor de base de datos . . . 15
  - 2.4.4. Anonimización con modelos formales: ARX . . . 15
  - 2.4.5. Generación de datos sintéticos . . . 16
  - 2.4.6. Detección de datos sensibles . . . 16
  - 2.4.7. Validación y evaluación . . . 17
  - 2.4.8. Otras herramientas relevadas . . . 17
  - 2.4.9. Licencias, continuidad y reutilización . . . 18
- 2.5. Integración de la inteligencia artificial en el proceso . . . 19

2.5.1. Clasificación de columnas sensibles . . . 19
2.5.2. Generación de filas con modelos de lenguaje . . . 20
2.5.3. Orquestación y llamado a funciones . . . 20
2.5.4. Privacidad y costo al usar modelos de lenguaje . . . 20
2.6. Integridad referencial y extracción de subconjuntos . . . 21
2.6.1. Claves primarias . . . 21
2.6.2. Claves foráneas y estructura relacional . . . 21
2.6.3. Extracción de subconjuntos . . . 22
2.6.4. Tipos de datos complejos . . . 22
2.7. Criterios y dimensiones de evaluación . . . 23
2.7.1. Utilidad para testing frente a utilidad para aprendizaje automático . . . 24
2.7.2. Cómo se mide el riesgo de privacidad . . . 25
2.8. Bases de datos de referencia . . . 25

3. Conclusiones y Trabajo Futuro **27**
3.1. Conclusiones del relevamiento . . . 27
3.2. Requisitos preliminares . . . 28
3.3. Preguntas abiertas . . . 29
3.4. Limitaciones y trabajo para la Etapa 2 . . . 29

Referencias **30**

A. Glosario **34**

Capítulo 1

Introducción

Este documento corresponde a la Etapa 1 del proyecto: el estudio de conceptos y enfoques de generación de bases de datos de preproducción representativas para testing, a partir de datos productivos, y de la integración de inteligencia artificial en ese proceso y en tareas específicas. Su producto es el informe de estado del arte (Resultado 1). Se presenta como una versión de avance: lo que ya está relevado se desarrolla por completo, y lo que todavía está en curso se indica de forma explícita en la Tabla 1.2.

1.1. Contexto y planteamiento del problema

Probar un sistema de software con datos realistas encuentra defectos que los datos inventados no encuentran: valores límite, combinaciones poco frecuentes, errores de calidad del dato, volúmenes y distribuciones propias del negocio. Esos datos existen en producción, pero en producción están los datos personales de clientes y usuarios, y los ambientes de prueba suelen tener controles de acceso y monitoreo más laxos. De ahí surge la tensión central del proyecto: mantener la utilidad de los datos para probar y, al mismo tiempo, reducir el riesgo de exponer o identificar información sensible. Una transformación excesiva destruye el valor para las pruebas; una insuficiente deja el riesgo de privacidad intacto.

En la práctica, poblar un ambiente de pruebas suele resolverse de tres maneras, y las tres tienen limitaciones importantes (Tabla 1.1).

Camino	Qué se hace	Por qué falla
Copia directa de producción	Restaurar un respaldo productivo en el ambiente de prueba	Máximo riesgo legal y de seguridad: el dato personal termina en el lugar menos protegido de la organización.
Datos completamente inventados	Faker, Mockaroo o scripts de semillas	No hay riesgo de privacidad, pero se pierde el realismo estadístico, la cardinalidad, los valores atípicos y la «suciedad» del dato real; los errores de producción no se reproducen en testing.
Enmascaramiento manual	Scripts SQL de `UPDATE` hechos a mano	Frágil ante cambios de esquema, difícil de mantener consistente entre tablas relacionadas, no verificable y típicamente incompleto: se enmascara lo obvio y se olvida lo indirecto.

Tabla 1.1: Caminos habituales para poblar un ambiente de pruebas y sus fallas.

Este proyecto explora una cuarta vía: un proceso reproducible, asistido por IA, que extraiga un subconjunto coherente de producción, aplique transformaciones con garantías medibles de privacidad y produzca una base de preproducción útil para testear y segura de exponer. La IA se concibe como un componente de apoyo dentro del proceso (por ejemplo, para clasificar qué campos son sensibles) y no como un mecanismo único de anonimización o de generación de datos.

1.2. Objetivos de la etapa

El objetivo de esta etapa es conocer el estado del arte sobre el problema descrito. Más específicamente:

- establecer un vocabulario técnico preciso sobre las técnicas de protección de datos y su situación frente a la normativa aplicable;
- describir y categorizar las técnicas de anonimización, de privacidad y de generación de datos sintéticos, y no solo las herramientas que las implementan;
- relevar las herramientas existentes y compararlas con criterios explícitos y fuentes verificables;
- revisar en qué tareas del proceso la inteligencia artificial aporta evidencia favorable y en cuáles no;
- identificar los problemas técnicos que siguen abiertos y los criterios de evaluación disponibles, para delimitar dónde el proyecto puede hacer un aporte propio.

1.3. Resultados esperados

El producto de esta etapa es el informe de estado del arte en generación de bases de datos de preproducción representativas para testing, a partir de datos

productivos, y la integración de inteligencia artificial en el proceso y en tareas específicas (Resultado 1 del proyecto). Se espera que el relevamiento permita: (i) establecer un vocabulario técnico preciso sobre las técnicas de protección de datos; (ii) elaborar una taxonomía funcional de las herramientas del sector; (iii) compararlas con criterios explícitos y fuentes verificables; (iv) identificar las restricciones técnicas que condicionan cualquier propuesta posterior; y (v) señalar los espacios del estado del arte que el proyecto tiene potencial de cubrir.

1.4. Alcance de esta etapa

Esta etapa *describe y compara*; no *evalúa ni selecciona*. El relevamiento, análisis y evaluación de propuestas y estrategias, incluida la definición de una propuesta propia, corresponde a la Etapa 2 y se documentará en su informe (Resultado 2). Por eso este documento no recomienda una pila tecnológica ni propone una arquitectura: los antecedentes relevados se usan para señalar vacíos y preguntas abiertas (Capítulo 3).

El alcance técnico se limita a bases de datos relacionales y a datos tabulares. Quedan fuera las bases documentales, de grafos y otras fuentes heterogéneas. La Tabla 1.2 resume el estado de cada sección de esta versión.

Sección	**Estado en esta versión**
2.1 Marco conceptual y regulatorio	Completa; fuentes por verificar
2.2 Técnicas de protección de datos	Completa
2.3 Generación de datos sintéticos	Completa
2.4 Relevamiento de herramientas	Completo en lo descriptivo; referencias por completar
2.5 Integración de la inteligencia artificial	Completa
2.6 Integridad referencial y subconjuntos	Completa
2.7 Criterios y dimensiones de evaluación	En curso: dimensiones definidas, métricas por concretar con el caso de estudio
2.8 Bases de datos de referencia	En curso: candidatas relevadas, selección pendiente
Pruebas exploratorias de herramientas	Documentadas aparte; su inclusión se define con la supervisión

Tabla 1.2: Estado de las secciones de esta versión.

1.5. Metodología del relevamiento

El relevamiento combinó cuatro tipos de fuentes: (i) la documentación oficial y los repositorios de cada herramienta; (ii) literatura académica y preprints sobre síntesis de datos tabulares, detección de datos personales y evaluación de privacidad; (iii) guías y normativa de protección de datos (Grupo del Artículo 29, EDPB, ICO, URCDP y la Ley N.º 18.331); y (iv) el material aportado por la supervisión y el cliente y las conversaciones de las reuniones de seguimiento. [**VERIFICAR: completar con las búsquedas, términos y bases bibliográficas efectivamente consultados**]

Se incluyeron herramientas y técnicas aplicables a datos tabulares y relacionales y relevantes para generar datos de prueba desde datos productivos, con documentación pública disponible. Se registraron también las herramientas que no resultan centrales para el caso de uso, junto con el motivo, para que la exclusión quede documentada (Sección 2.4.8).

El relevamiento es documental. Las capacidades de cada herramienta se toman de su documentación y de las publicaciones citadas, y se marcan como tales; las pruebas propias se documentan aparte. Dos cautelas: el mercado de estas herramientas cambia con rapidez (licencias, adquisiciones, versiones), por lo que los datos corresponden a setiembre y octubre de 2026 y deben reverificarse antes de la defensa; y varias guías regulatorias citadas están en proceso de consulta, por lo que su texto puede cambiar.

1.6. Conclusiones principales

Las conclusiones del relevamiento se desarrollan en el Capítulo 3; en resumen: (i) ninguna herramienta relevada cubre sola el proceso completo con una licencia utilizable en este trabajo; (ii) lo menos resuelto es decidir qué proteger y cómo, sobre todo en esquemas relacionales; (iii) la evidencia favorece el uso de modelos de lenguaje para clasificar columnas sensibles y lo desfavorece para generar filas; y (iv) preservar la integridad referencial al sintetizar datos relacionales y medir la utilidad de una base para testing de software son los problemas con más espacio para un aporte propio.

1.7. Organización del documento

El Capítulo 2 desarrolla la revisión de antecedentes: el marco conceptual y regulatorio, las técnicas de protección y de generación de datos, el relevamiento de herramientas, el rol de la inteligencia artificial, el problema de la integridad referencial, los criterios de evaluación y las bases de datos de referencia. El Capítulo 3 presenta las conclusiones, los requisitos preliminares, las preguntas abiertas y lo que resta para la Etapa 2. Al final se incluyen las referencias y, como anexo, un glosario (Anexo A).

Capítulo 2

Revisión de antecedentes

Este capítulo desarrolla el estado del arte. Primero fija el vocabulario y el marco normativo (Sección 2.1); después revisa las técnicas de protección de datos (Sección 2.2) y de generación de datos sintéticos (Sección 2.3); luego se relevan las herramientas disponibles (Sección 2.4), el rol de la inteligencia artificial (Sección 2.5), el problema de la integridad referencial (Sección 2.6) y los criterios de evaluación (Sección 2.7); y cierra con las bases de datos de referencia candidatas (Sección 2.8).

2.1. Marco conceptual y regulatorio

2.1.1. Conceptos básicos

Un *dato personal* es información relativa a una persona identificada o identificable. Los *identificadores directos* (nombre, cédula de identidad, correo electrónico) identifican a una persona por sí solos. Los *cuasi-identificadores* (fecha de nacimiento, código postal, sexo, ocupación) no la identifican individualmente, pero su combinación puede hacerlo: Sweeney estimó que, en el censo de 1990 de Estados Unidos, el 87 % de la población quedaba identificada de forma única por código postal, fecha de nacimiento y sexo (Sweeney, 2000). Los *atributos sensibles* (por ejemplo, salud o ingresos) son los que más daño causan al asociarse a una persona identificada.

La *reidentificación* es el proceso de volver a asociar un registro supuestamente protegido con una persona. El Grupo de Trabajo del Artículo 29 propone evaluarla mediante tres riesgos (Article 29 Data Protection Working Party, 2014):

- *singling out* (individualización): aislar uno o varios registros que identifican a una persona;
- *linkability* (vinculabilidad): vincular al menos dos registros que corresponden a la misma persona o grupo, aunque estén en bases distintas;

- *inference* (inferencia): deducir con probabilidad significativa el valor de un atributo a partir de otros.

Estos tres riesgos son la referencia técnica que se usa en el resto del documento, y son los que mide la herramienta Anonymeter (Sección 2.4.7).

2.1.2. Taxonomía de técnicas de protección

Antes de comparar herramientas conviene fijar el vocabulario, porque el uso comercial de estos términos no es preciso. La Tabla 2.1 distingue *objetivos* (qué se quiere lograr), *técnicas* (cómo se logra) y *familias* (agrupaciones de técnicas), que es una diferencia que suele mezclarse.

Concepto	**Tipo**	**Qué es o qué hace**	**¿Se puede deshacer?**	**¿Sigue siendo dato personal?**
Enmascaramiento (*masking*)	Técnica	Reemplaza u oculta valores. *Estático*: modifica de forma permanente una copia. *Dinámico*: oculta el valor al consultar, pero el original sigue en la base.	Estático: no, si no se guardó una correspondencia. Dinámico: el original sigue existiendo.	Sí, si quedan cuasi-identificadores que permitan identificar.
Seudonimización	Técnica (definida en el GDPR)	Reemplaza identificadores por referencias y guarda por separado la información adicional que permite revertirlo.	Sí, con esa información adicional.	Sí (considerando 26 del GDPR).
Anonimización	Objetivo o resultado	Datos que ya no permiten identificar a nadie con los medios razonablemente disponibles. Se logra aplicando técnicas (generalización, ruido, síntesis, entre otras).	No.	No, si supera el análisis de riesgo.
Datos sintéticos	Técnica	Registros nuevos generados por un modelo que aprendió la distribución de los datos originales.	No hay correspondencia que revertir, pero el modelo puede filtrar registros reales.	No puede asumirse que no lo sean: hay que evaluarlo después de generar.
PETs (*privacy-enhancing technologies*)	Familia	Tecnologías que minimizan, ocultan o fragmentan el dato durante su procesamiento. Incluye privacidad diferencial y datos sintéticos.	Depende de cada una.	Depende de cada una.

Tabla 2.1: Taxonomía de técnicas de protección de datos.

Tres aclaraciones. Primero, la anonimización es un *resultado*: se alcanza aplicando técnicas y se juzga con un análisis de riesgo, no por el nombre de la técnica usada. La Opinión 05/2014 agrupa las técnicas en dos familias, la *aleatorización* (adición de ruido, permutación, privacidad diferencial) y la *generalización* (agregación, k-anonimato, l-diversidad) (Article 29 Data Protection Working

Party, 2014). Segundo, el ICO británico incluye los datos sintéticos entre las ocho PETs que describe (Information Commissioner's Office, 2023); por eso no corresponde presentarlos como una categoría separada de las PETs. Tercero, *reversible* y *reidentificable* son cosas distintas: la primera describe si existe un camino técnico para deshacer la transformación, y la segunda si alguien puede, con otros medios, volver a identificar a una persona. Un dato anonimizado no es reversible, pero puede seguir siendo reidentificable si la anonimización fue débil. [**VERIFICAR: contrastar con el texto del ICO la redacción sobre datos sintéticos y anonimato**]

2.1.3. Marco regulatorio aplicable

Unión Europea. El Reglamento General de Protección de Datos (GDPR) distingue entre datos seudonimizados y anónimos (Parlamento Europeo y Consejo de la Unión Europea, 2016). Los primeros siguen siendo datos personales, porque la información adicional que permite atribuirlos a una persona existe y se conserva por separado (artículo 4(5) y considerando 26). Los segundos quedan fuera del reglamento solo si la persona no es identificable considerando los medios que razonablemente podrían usarse para identificarla (considerando 26). La Opinión 05/2014 del Grupo del Artículo 29 desarrolló los tres riesgos de la Sección 2.1.1 como criterio para juzgar si una anonimización es efectiva (Article 29 Data Protection Working Party, 2014).

Dos desarrollos recientes son relevantes. Por un lado, la sentencia del Tribunal de Justicia de la Unión Europea del 4 de setiembre de 2025 (asunto C-413/23 P, EDPS contra SRB) estableció que los datos seudonimizados no son necesariamente datos personales para todo receptor: depende de si quien los recibe tiene medios razonables para reidentificar (Tribunal de Justicia de la Unión Europea, 2025). Esto es pertinente para un ambiente de preproducción, porque el mismo conjunto de datos puede ser personal para el equipo de producción y no serlo para quien carece de la tabla de equivalencias. Por otro lado, en julio de 2026 el EDPB adoptó, para consulta pública hasta el 30 de octubre de 2026, las Guías 02/2026 sobre anonimización, que buscan aclarar la noción de dato anónimo y ofrecer un marco práctico para determinar si una anonimización fue exitosa (European Data Protection Board, 2026). Al ser un borrador, su contenido puede cambiar, y las guías del EDPB interpretan el GDPR pero no son una norma por sí mismas.

Reino Unido. El ICO publica guías sobre anonimización y sobre PETs (Information Commissioner's Office, 2025, 2023). La segunda describe ocho tecnologías, entre ellas la privacidad diferencial y los datos sintéticos, y es la referencia técnica más accesible sobre el tema.

Uruguay. La norma rectora es la Ley N.º 18.331 de Protección de Datos Personales y Acción de Habeas Data (2008), reglamentada por el Decreto 414/009, y la autoridad de control es la Unidad Reguladora y de Control de Datos Per-

sonales (URCDP) (República Oriental del Uruguay, 2008). La Guía de criterios de disociación de datos personales de la URCDP, aprobada por la Resolución 68/017 del 26 de abril de 2017 en el contexto de la publicación de datos abiertos, define la *disociación* como todo tratamiento de datos personales que impide vincular la información obtenida con una persona determinada o determinable, y la *anonimización* como el resultado de un tratamiento que impide su identificación de forma irreversible (Unidad Reguladora y de Control de Datos Personales, 2017). La distinción es análoga a la europea. Uruguay cuenta además con una decisión de adecuación de la Comisión Europea. [**VERIFICAR: citar la Decisión 2012/484/UE y su revisión de 2024**]

Implicancia para el proyecto. Como criterio técnico se adoptan los tres riesgos del Grupo del Artículo 29, que son compatibles con el marco europeo y con el uruguayo. La valoración jurídica final de un caso concreto excede el alcance de este trabajo.

2.2. Técnicas de protección de datos

2.2.1. Enmascaramiento y seudonimización

Las técnicas deterministas declaran, para cada columna, una transformación explícita: sustituir por un valor falso, mezclar valores dentro de la columna (*shuffling*), generalizar a un rango, suprimir, agregar ruido acotado, aplicar una función *hash* con sal, tokenizar o cifrar preservando el formato. Su ventaja es que son auditables, preservan el esquema por construcción y no tienen riesgo de memorización. Su límite es que, aplicadas columna a columna, no preservan correlaciones entre columnas (por ejemplo, si se aleatorizan por separado la ciudad y el código postal se rompe su relación), no generan volumen nuevo (transforman N filas en N filas) y requieren que alguien decida qué transformar.

Al tratar identificadores hay un cuidado específico. Un *hash* de un valor de dominio pequeño no protege: la cédula de identidad uruguaya tiene del orden de diez millones de valores posibles, por lo que su *hash* se invierte por fuerza bruta si no se usa una sal larga y secreta. Y cuando se quiere mantener la consistencia entre tablas (el mismo identificador debe producir siempre el mismo seudónimo), la tabla de correspondencia pasa a ser la «información adicional» que mantiene el dato como personal, y se convierte en el activo más sensible a proteger.

2.2.2. Modelos formales de anonimato

El *k-anonimato* exige que cada registro sea indistinguible de al menos $k-1$ registros más respecto de sus cuasi-identificadores (Sweeney, 2002). Se logra generalizando valores (por ejemplo, edad exacta por rango) y suprimiendo registros atípicos. No protege contra la inferencia cuando los registros de un grupo comparten el mismo atributo sensible; la *l-diversidad* (Machanavajjhala, Kifer,

Gehrke, y Venkitasubramaniam, 2007) y la *t-cercanía* (Li, Li, y Venkatasubramanian, 2007) agregan condiciones sobre la distribución del atributo sensible dentro de cada grupo.

Estos modelos tienen límites conocidos para el caso de uso de este proyecto. Con muchas columnas (alta dimensionalidad) la generalización necesaria para alcanzar un k razonable destruye la utilidad del dato (Aggarwal, 2005); suponen que se conocen de antemano cuáles son los cuasi-identificadores; y operan sobre una tabla plana, no sobre esquemas relacionales. ARX (Sección 2.4.4) es la implementación de referencia.

2.2.3. Privacidad diferencial

La privacidad diferencial es una garantía matemática sobre el *resultado* de un procesamiento. Un mecanismo es ε-diferencialmente privado si su salida cambia muy poco (en un factor de e^{ε}) cuando se agrega o se quita el registro de una sola persona (Dwork, McSherry, Nissim, y Smith, 2006; Dwork y Roth, 2014). El parámetro ε es el *presupuesto de privacidad*: cuanto menor, más protección y más ruido. Como el presupuesto se consume en cada liberación de resultados sobre las mismas personas, regenerar un ambiente de forma periódica acumula pérdida de privacidad, un aspecto que suele pasarse por alto.

Aplicada a modelos generativos, la técnica habitual es DP-SGD: durante el entrenamiento se recorta el gradiente de cada ejemplo y se le suma ruido calibrado, de modo que ningún registro individual influya demasiado en el modelo (Abadi y cols., 2016). Es una opción disponible en algunos generadores (Sección 2.4.5).

Conviene precisar qué *no* garantiza. Protege la salida, no la entrada: los datos originales retenidos siguen siendo datos personales. No equivale automáticamente a anonimización en sentido legal, y el ICO advierte que una configuración inadecuada puede dejar riesgo de fuga (Information Commissioner's Office, 2023). Y siempre cuesta utilidad: un ε muy bajo vuelve inútil el dato, y elegir un valor adecuado requiere criterio experto.

2.2.4. Otras tecnologías de mejora de la privacidad

La guía del ICO enumera ocho PETs: privacidad diferencial, datos sintéticos, cifrado homomórfico, pruebas de conocimiento cero, entornos de ejecución confiables, cómputo multipartito seguro, intersección privada de conjuntos y aprendizaje federado (Information Commissioner's Office, 2023). Salvo las dos primeras, están orientadas a procesar o compartir cómputo entre partes sin revelar los datos, y no producen una base de datos de prueba; por eso quedan fuera del foco de este trabajo.

2.3. Generación de datos sintéticos

2.3.1. Datos inventados y datos aprendidos

Conviene separar dos clases. Los generadores *sin datos reales* (Faker, Mockaroo) producen valores plausibles a partir de reglas y catálogos (nombres, direcciones, fechas) sin aprender nada del dato productivo. Son útiles como componente auxiliar, por ejemplo para generar valores de reemplazo, pero no capturan distribuciones ni correlaciones. Los generadores *aprendidos* entrenan un modelo con los datos reales y luego muestrean filas nuevas; preservan correlaciones entre columnas (incluidas dependencias que nadie codificó), permiten generar más o menos volumen que el original y condicionar el muestreo (por ejemplo, forzar una proporción de una categoría), a cambio de costo computacional y de riesgo de memorización. Ninguno de los dos enfoques, el determinista de la Sección 2.2.1 y el generativo, cubre solo todos los requisitos de una base de preproducción (Tabla 2.2).

Requisito de una base de preproducción	**Determinista**	**Generativo**
Claves primarias únicas y estables	Sí	No
Claves foráneas que resuelven	Sí	Parcial (solo con modelo relacional específico)
Formatos que pasan las validaciones de la aplicación	Sí	Parcial
Restricciones de negocio (invariantes, fechas ordenadas)	Sí	No, salvo con una capa de restricciones
Distribuciones marginales y correlaciones realistas	No	Sí
Casos borde realistas	No	Parcial
Volumen ajustable	No	Sí
Auditabilidad	Sí	Parcial (requiere medición posterior)
Descubrimiento automático de qué proteger	No	No

Tabla 2.2: Cobertura de los requisitos de una base de preproducción según el enfoque.

La última fila es la que abre espacio a la inteligencia artificial: ninguno de los dos enfoques decide por sí mismo qué columnas requieren protección ni qué tratamiento corresponde a cada una (Sección 2.5).

2.3.2. Familias de modelos generativos tabulares

La Tabla 2.3 resume las familias principales. Se presentan por familia y no por producto, porque la documentación de varias herramientas todavía se apoya en arquitecturas de 2019.

Familia	Ejemplos	Característica	Limitación señalada
Estadísticos clásicos	Cópulas gaussianas, redes bayesianas (Patki, Wedge, y Veeramachaneni, 2016)	Rápidos, interpretables, sin GPU.	Capturan dependencias limitadas entre columnas.
GAN tabulares	CTGAN (Xu, Skoularidou, Cuesta-Infante, y Veeramachaneni, 2019), basado en redes generativas adversarias (Goodfellow y cols., 2014)	Tratan columnas continuas y discretas con normalización y muestreo condicional.	Entrenamiento costoso e inestable.
VAE tabulares	TVAE (Xu y cols., 2019), basado en autocodificadores variacionales (Kingma y Welling, 2014)	Más estables que las GAN en algunos casos.	Requieren ajuste cuidadoso.
Basados en árboles	Bosques aleatorios adversariales (Watson, Blesch, Kapar, y Wright, 2023)	Bajo costo computacional.	El tratamiento de esquemas relacionales no es su foco.
Difusión	TabDDPM (Kotelnikov, Baranchuk, Rubachev, y Babenko, 2023)	Alta fidelidad reportada en tabla única.	Costo alto de entrenamiento y generación.
Autorregresivos y transformers	GReaT (Borisov, Seßler, Leemann, Pawelczyk, y Kasneci, 2023), REaLTabFormer (Solatorio y Dupriez, 2023), TabularARGN (Tiwald y cols., 2025)	Cada columna se genera condicionada a las anteriores de la fila.	Sensibles al orden de las columnas; los dos primeros serializan filas como texto.
Relacionales (multi-tabla)	HMA (DataCebo, 2025a), ClavaDDPM (Pang y cols., 2024), PrivLava (Cai, Xiao, y Cormode, 2023), RelDiff (Hudovernik y cols., 2025)	Modelan explícitamente relaciones padre-hijo y claves foráneas.	Área menos madura; escalabilidad limitada (Sección 2.6).

Tabla 2.3: Familias de modelos generativos tabulares.

Los autores de TabularARGN reportan resultados competitivos frente a modelos más costosos computacionalmente (Tiwald y cols., 2025). [**VERIFICAR: confirmar en el artículo las cifras y los conjuntos de datos del benchmark antes de afirmar algo más específico**]

2.3.3. Riesgos de los datos sintéticos

Un dato sintético no es anónimo por definición. Un generador que reproduce demasiado bien sus datos de entrenamiento puede estar copiando registros reales, y existen ataques de inferencia de pertenencia que determinan si un registro estuvo en el entrenamiento (Shokri, Stronati, Song, y Shmatikov, 2017); en modelos de lenguaje se documentó, además, la extracción de fragmentos textuales del entrenamiento (Carlini y cols., 2021). A mayor fidelidad del dato sinté-

tico, mayor es su utilidad, pero también la probabilidad de revelar información personal; no existe una configuración que maximice ambas. Por eso cualquier propuesta debe incluir una evaluación de privacidad posterior a la generación (Sección 2.7), y no solo una técnica de generación.

2.4. Relevamiento de herramientas

2.4.1. Criterios de organización

Las herramientas se organizan por *lo que hacen* y no por su popularidad o su licencia, porque operan de forma complementaria sobre etapas distintas del proceso. Para cada una se registran sus capacidades (si genera datos, si anonimiza, si detecta datos sensibles, si extrae subconjuntos, si valida), su licencia y costo, si puede ejecutarse dentro del perímetro propio, si maneja esquemas relacionales de varias tablas y qué fuentes de datos admite. La Tabla 2.4 resume las capacidades y la Tabla 2.5 los aspectos de adopción. Ambas reflejan lo que indica la documentación de cada herramienta: ninguna celda proviene todavía de una prueba propia. Una celda con un asterisco (*) indica un dato por confirmar contra la fuente.

Herramienta	**Genera datos**	**Anonimiza o enmascara**	**Detecta datos sensibles**	**Extrae subconjuntos**	**Valida resultado**
Faker, Mockaroo	Parcial (por reglas, sin aprender)	No	No	No	No
PostgreSQL Anonymizer	No	Sí	Parcial (por diccionario de nombres)	No	No
Enmascaramiento nativo de motores	No	Parcial (principalmente dinámico)	No	Parcial (según el motor)*	No
ARX	No	Sí	No	No	Parcial (riesgo de reidentificación sobre una tabla)
Presidio	No	Sí (reversible con cifrado)	Sí	No	No
GLiNER	No	No	Sí	No	No
Tonic.ai	Sí	Sí	Sí	Sí	Parcial*
Delphix	No	Sí	Sí	Parcial*	No
SDV	Sí	No	No	No	Sí (con SDMetrics)
MOSTLY AI SDK	Sí	No	No	No	Sí (reportes propios)
Anonymeter, SDMetrics, SyntheRela, SynthEval	No	No	No	No	Sí

Tabla 2.4: Capacidades funcionales de las herramientas relevadas, según su documentación.

Herramienta	**Licencia**	**Ejecución en el perímetro propio**	**Varias tablas relacionadas**	**Fuente de datos y extensibilidad**
Faker	MIT	Sí	No aplica	Librería; se extiende con proveedores propios.
Mockaroo	Comercial (con plan gratuito)	Parcial (versión autohospedada paga)*	Manual	Esquema definido a mano.
PostgreSQL Anonymizer	Licencia PostgreSQL	Sí (corre en el motor)	Columna a columna; consistencia vía seudonimización determinista	Solo PostgreSQL.
ARX	Apache 2.0	Sí	No (tabla única)	Archivos y bases por JDBC*; interfaz gráfica y API Java.
Presidio	MIT	Sí	No aplica (por columna o texto)	Texto y datos tabulares (`presidio-structured`); admite reconocedores propios.
GLiNER	Variable según el modelo*	Sí (CPU)	No aplica	Texto.
Tonic.ai	Propietaria; precio no público	Parcial (agente local, control en la nube)*	Sí	Varios motores relacionales.
Delphix	Propietaria; precio no público	Sí	Sí	Varios motores relacionales.
SDV	BSL 1.1 (SDMetrics: MIT)	Sí	Sí, con límites documentados (Sección 2.6)	Datos ya extraídos (tablas en memoria).
MOSTLY AI SDK	Apache 2.0	Sí (modo local)	Sí (mediante claves de contexto)	Datos ya extraídos (tablas en memoria o archivos).*
Anonymeter	BSD (Clear)	Sí	No aplica	Tablas original, sintética y de control.

Tabla 2.5: Aspectos de adopción de las herramientas relevadas, según su documentación.

2.4.2. Plataformas comerciales integrales

Tonic.ai y Delphix cubren buena parte del proceso. Tonic.ai ofrece módulos de enmascarado y síntesis sobre bases estructuradas, extracción de subconjuntos, desidentificación de texto libre y generación de bases relacionales (Tonic.ai, 2026). Delphix combina la virtualización de bases de datos con módulos de descubrimiento de datos sensibles y enmascarado (Perforce, 2026). Ambas son propietarias y con precios no públicos; las referencias de terceros ubican su costo en el orden de cientos de miles de dólares anuales. **[VERIFICAR: no hay**

una fuente primaria; circulan cifras distintas (entre unos 150.000 y 370.000 USD anuales); citar una fuente concreta o eliminar la cifra] No se encontró documentación pública detallada de sus algoritmos de enmascarado y síntesis, de modo que no son reproducibles ni inspeccionables. Se las toma como referencia de las capacidades funcionales que un proceso completo puede cubrir, y no como base técnica para el proyecto. Existen otras suites del mismo tipo (Informatica, IBM Optim, K2View, Redgate Data Masker, DATPROF, Broadcom), que no se analizan en detalle por la misma razón.

2.4.3. Anonimización a nivel de motor de base de datos

PostgreSQL Anonymizer es una extensión de código abierto que permite declarar reglas de anonimización sobre las columnas mediante etiquetas de seguridad (`SECURITY LABEL`), de modo que las reglas viven en el propio esquema y se versionan junto con él (Dalibo, 2025). Ofrece varias estrategias: exportaciones anonimizadas a un archivo SQL, enmascaramiento estático sobre una copia, enmascaramiento dinámico por rol y vistas enmascaradas. Su principal ventaja para este proyecto es que las transformaciones se ejecutan dentro del motor, por lo que el dato no sale de PostgreSQL. Incluye una función de detección de columnas sospechosas basada en diccionarios de nombres de columna (la documentación consultada menciona diccionarios en inglés y en francés, no en español). [**VERIFICAR: confirmar los idiomas disponibles en la versión vigente**] Sus límites son los del enfoque determinista (Sección 2.2.1): no preserva correlaciones entre columnas, no genera volumen nuevo y solo sirve para PostgreSQL.

Otros motores traen funciones nativas de enmascaramiento, pero están pensadas para limitar la exposición en producción y no para producir copias seguras persistidas. El *Dynamic Data Masking* de SQL Server oculta el dato al consultar y no modifica el contenido de la base (Microsoft, 2025b). Oracle y MySQL ofrecen funciones de enmascaramiento y de extracción de subconjuntos como componentes de sus ediciones comerciales. [**VERIFICAR: citar la documentación de Oracle (Data Masking and Subsetting Pack) y de MySQL Enterprise Data Masking**]

2.4.4. Anonimización con modelos formales: ARX

ARX es una herramienta de código abierto (Apache 2.0) que implementa los modelos de la Sección 2.2.2 (k-anonimato, l-diversidad, t-cercanía, δ-presencia) y la privacidad diferencial, con análisis cuantitativo de riesgo de reidentificación y de pérdida de utilidad (Prasser y Kohlmayer, 2015). Trabaja sobre una tabla plana, por lo que no modela esquemas relacionales ni integridad referencial. Su aporte para este proyecto es como instrumento de validación: reportar el nivel de k-anonimato alcanzado por una tabla del resultado. Herramientas del mismo tipo son Amnesia, sdcMicro y µ-ARGUS (Sección 2.4.8).

2.4.5. Generación de datos sintéticos

SDV (*Synthetic Data Vault*) nació en el MIT (Patki y cols., 2016) y es el ecosistema de código abierto más extendido; soporta una tabla, varias tablas y secuencias, e incluye un sistema de restricciones lógicas que fuerza al generador a respetar reglas del dominio. En abril de 2023 DataCebo cambió la licencia de la mayoría de sus bibliotecas a Business Source License 1.1: el uso no productivo está siempre permitido, el uso productivo tiene restricciones adicionales (por ejemplo, productos comerciales construidos sobre SDV), y cada versión se convierte en MIT a los cuatro años. La biblioteca de métricas SDMetrics se mantuvo bajo MIT (DataCebo, 2023). Para esquemas de varias tablas, la documentación de su sintetizador jerárquico (HMA) indica un rendimiento óptimo para alrededor de cinco tablas y un solo nivel de profundidad (DataCebo, 2025a). [**VERIFICAR: contrastar con la versión vigente de la documentación**]

MOSTLY AI SDK es una biblioteca de Python con licencia Apache 2.0 (MOSTLY AI, 2025). Implementa TabularARGN (Tiwald y cols., 2025; Krchova, Vargas Vieyra, Scriminaci, y Sidorenko, 2025), una red neuronal autorregresiva diseñada para datos tabulares. No es un modelo de lenguaje ni un agente conversacional: se instancia con pesos aleatorios y se entrena desde cero con el conjunto que se le entrega, y el resultado es un *generador* que puede guardarse y reutilizarse. Admite un modo local, donde el entrenamiento y la generación ocurren en infraestructura propia, y un modo cliente que delega el cómputo a la plataforma del proveedor. Para esquemas relacionales permite entrenar un único generador sobre varias tablas vinculadas por claves foráneas, distinguiendo claves de contexto (que definen la jerarquía padre-hijo) de claves no contextuales; las claves primarias no se modelan y se regeneran. Permite además condicionar el muestreo y rebalancear columnas categóricas, e incorpora privacidad diferencial opcional mediante DP-SGD. [**VERIFICAR: confirmar cada una de estas capacidades y sus restricciones en la documentación vigente**]

Siempre se necesita un conjunto de datos de entrenamiento: ninguna de las dos herramientas genera datos solo a partir de un esquema. Para ese escenario existen paquetes aparte que usan modelos de lenguaje de proveedores externos, lo que reintroduce la dependencia de servicios en la nube.

2.4.6. Detección de datos sensibles

Microsoft Presidio combina reconocimiento de entidades (con modelos como spaCy), expresiones regulares y validaciones por suma de verificación (Microsoft, 2025c). Incluye operadores de anonimización (reemplazar, redactar, enmascarar, aplicar *hash* o cifrar), y el cifrado puede revertirse, lo que permite una desanonimización controlada, por ejemplo para depurar un error que solo aparece con un dato real. Su módulo `presidio-structured` está orientado a datos tabulares. Los reconocedores incluidos están pensados sobre todo para formatos de otros países; un dato local como la cédula de identidad uruguaya requeriría reconocedores propios. [**VERIFICAR: confirmar en la documentación**]

GLiNER es un modelo de reconocimiento de entidades nombradas (NER) que no requiere ejemplos previos para cada tipo de entidad, con menos de 500 millones de parámetros que corre en CPU (Zaratiana, Tomeh, Holat, y Charnois, 2024). Su variante GLiNER2-PII, de 0,3 mil millones de parámetros, reconoce 42 tipos de entidades de datos personales (Zaratiana, Lewis, y Hurn-Maloney, 2026); sus autores reportan un F1 promedio de 0,47 en el benchmark SPY, superior al de otros modelos pequeños comparados pero bajo en términos absolutos. Por ello, no puede presentarse como equivalente a un modelo de lenguaje grande sin una evaluación propia.

2.4.7. Validación y evaluación

Anonymeter mide el riesgo de reidentificación de datos sintéticos con un diseño de tres ataques, uno por cada riesgo de la Sección 2.1.1 (Giomi, Boenisch, Wehmeyer, y Tasnádi, 2023). Se compara un ataque principal, que usa los datos sintéticos para adivinar sobre los registros usados en el entrenamiento, con un ataque de control, que lo hace sobre registros reales no usados en el entrenamiento. Si el ataque principal no supera significativamente al de control, se interpreta que el modelo no aprendió nada específico de los registros de entrenamiento, más allá de la distribución general. Requiere, por lo tanto, separar de antemano un conjunto de control.

SDMetrics (MIT) mide fidelidad estadística, por ejemplo la forma de cada columna y las tendencias entre pares de columnas (DataCebo, 2025b). **SyntheRela** es un benchmark específico para datos relacionales sintéticos, con medidas de similitud de cardinalidades y de correlación entre tablas conectadas (Hudovernik, Jurkovič, y Štrumbelj, 2024). **SynthEval** es un marco unificado de fidelidad, utilidad y privacidad (Lautrup y cols., 2025).

2.4.8. Otras herramientas relevadas

La Tabla 2.6 registra las herramientas que se relevaron y no resultan centrales para el caso de uso, con el motivo. [**VERIFICAR: agregar la referencia oficial de cada una**]

Herramienta	Categoría	Observación
Amnesia, sdcMicro, µ-ARGUS	Control de divulgación estadística	Implementan k-anonimato y variantes; usadas por oficinas de estadística; trabajan sobre tablas planas como ARX.
OpenDP, SmartNoise, diffprivlib	Privacidad diferencial	Ofrecen garantía formal, con costo en utilidad del dato; relevantes para fundamentar por qué no se adopta esta vía como única.
DataHub, OpenMetadata, Apache Atlas	Catálogos de datos	Clasifican y etiquetan columnas sin modelos de lenguaje; son el enfoque predominante en la industria frente al cual se contrasta el enfoque asistido por IA.
Google Cloud Sensitive Data Protection, AWS Macie	Servicios gestionados	Requieren enviar datos a servicios externos, lo que choca con la restricción de no exponer datos productivos.
Piiranha	Detección de datos personales	Modelo afinado para texto, no para columnas de bases de datos.
Mimesis	Generación por reglas	Alternativa a Faker para valores de reemplazo.
synthcity	Biblioteca de generadores y métricas	Reúne varios generadores y métricas de privacidad en un marco único; útil para comparativas.
REaLTabFormer	Síntesis relacional	Soporta una relación padre-hijo entre dos tablas, no esquemas relacionales arbitrarios (Solatorio y Dupriez, 2023).
Gretel	Síntesis y privacidad	Adquirida por NVIDIA (reportado en marzo de 2025) (TechCrunch, 2025); su continuidad como producto independiente debe verificarse.

Tabla 2.6: Otras herramientas relevadas y motivo por el que no son centrales.

2.4.9. Licencias, continuidad y reutilización

La licencia condiciona lo que se puede hacer con una herramienta. Una herramienta de uso gratuito (*freeware*) no es necesariamente de código abierto: que el código esté visible en un repositorio no implica que pueda modificarse y usarse como base. Las licencias permisivas (MIT, Apache 2.0, BSD) permiten construir sobre la herramienta, extenderla y contribuir de vuelta; la BSL 1.1 permite el uso no productivo, pero restringe el uso productivo y comercial. Para un proyecto de grado la BSL no es un obstáculo, pero sí lo es para que el resultado se use después en otro contexto.

El mercado además cambia rápido. SDV cambió de licencia en 2023 (DataCebo, 2023); Gretel fue adquirida por NVIDIA (TechCrunch, 2025); y la marca MOSTLY AI fue adquirida por Syntho en junio de 2026, aunque su SDK sigue disponible bajo Apache 2.0 según su repositorio. [**VERIFICAR: solo se encontraron fuentes secundarias de la adquisición de MOSTLY AI; citar el comunicado oficial**] La consecuencia es de diseño: conviene apoyarse en componentes con licencia permisiva y ejecución local, y mantener alternativas, porque la continuidad de un producto no está garantizada. Todos estos datos deben reverificarse antes de la defensa.

2.5. Integración de la inteligencia artificial en el proceso

Bajo «usar IA» se agrupan tareas muy distintas, y la evidencia relevada es favorable para algunas y desfavorable para otras. Se separan tres.

2.5.1. Clasificación de columnas sensibles

Es la tarea en la que la evidencia es más favorable. Un clasificador basado en reglas, como Presidio, evalúa cada columna de forma aislada. Un modelo de lenguaje puede, en cambio, recibir además los nombres de las demás columnas y la descripción del conjunto de datos, y resolver casos ambiguos: una columna cuyo nombre no dice nada (un código de reserva, un número de billete) puede identificar a una persona, algo que solo se deduce con el contexto de las demás columnas.

Agisha Ntwali, Rück y Heckmann comparan tres enfoques sobre cuatro conjuntos de datos (Agisha Ntwali, Rück, y Heckmann, 2025). La Tabla 2.7 reproduce sus resultados.

Conjunto de datos (F1 macro)	**Presidio**	**CASSED**	**GPT-4o con contexto**
DeSSI (sintético, 6272 columnas)	0,793	0,996	0,766
Kaggle (13 conjuntos reales)	0,293	0,349	0,902
OpenML (20 conjuntos reales)	0,684	0,501	0,964
MIMIC-Demo-Ext (clínico real)	0,662	0,724	0,829
Promedio	0,608	0,643	0,865

Tabla 2.7: Comparación de enfoques de detección de datos personales en datos estructurados.

Fuente: Agisha Ntwali y cols. (2025).

La tabla debe leerse con tres reservas. Primero, el estudio evaluó solo GPT-4o, un servicio en la nube; el promedio de 0,865 no puede extenderse a otros modelos. Segundo, CASSED obtiene 0,996 en DeSSI porque fue entrenado sobre ese mismo conjunto, lo que ilustra el sobreajuste y no su desempeño general, y en ese conjunto sintético el enfoque con GPT-4o rinde menos que Presidio. Tercero, los propios autores señalan que las tasas de falsos negativos en datos reales siguen siendo demasiado altas para uso práctico (un falso negativo es un dato personal que pasa sin protección), que enviar datos a un servidor externo es un problema de cumplimiento, y que el costo computacional es órdenes de magnitud mayor que el de Presidio.

Un segundo antecedente matiza el panorama. PIIBench unifica diez conjuntos de datos en 2.369.883 secuencias con 48 tipos de entidad, y reporta que ningún sistema evaluado supera un F1 de 0,14 a nivel de *span*, con Presidio como el mejor (0,1385) (Jha, 2026). Ese benchmark es de datos personales en *texto*, no en columnas de bases de datos, por lo que no es directamente comparable; sí sugiere que los valores altos obtenidos sobre conjuntos individuales no

se trasladan a escenarios heterogéneos y que hay que validar sobre los datos del propio dominio.

En resumen: dar contexto del esquema mejora la clasificación respecto de las reglas, pero no hay evidencia suficiente todavía sobre modelos locales más pequeños en bases relacionales, y las tasas de falsos negativos exigen mantener a una persona en el circuito de decisión.

2.5.2. Generación de filas con modelos de lenguaje

Existen enfoques que modelan tablas con modelos de lenguaje (Borisov y cols., 2023; Solatorio y Dupriez, 2023), pero la literatura y los propios fabricantes de generadores tabulares señalan inconvenientes para generar volumen: el costo por fila es alto, no hay garantías sobre la distribución conjunta que el modelo reproduce y, si el modelo se ajusta con datos reales, puede memorizarlos y filtrarlos (Carlini y cols., 2021). Los autores de TabularARGN diseñaron una arquitectura específica para datos tabulares precisamente para evitar tratar la tabla como texto (Tiwald y cols., 2025). Para el caso de uso de este proyecto, partir de datos productivos existentes, estos enfoques no resultan competitivos frente a generadores tabulares especializados.

2.5.3. Orquestación y llamado a funciones

El tercer uso consiste en que el modelo no produzca datos sino *decisiones o configuraciones*: traducir una regla de negocio escrita en lenguaje natural a una restricción formal, proponer qué estrategia de protección aplicar a cada columna, detectar relaciones no declaradas en el esquema o elegir qué función invocar entre un conjunto de funciones implementadas por el equipo (*function calling*). La salida del modelo se restringe a una estructura (por ejemplo un JSON con un esquema fijo, mediante decodificación restringida) y un componente determinista la valida y ejecuta, de modo que el modelo nunca es el dato ni ejecuta consultas por su cuenta. Esto mantiene al modelo fuera de la ruta crítica de corrección y acota el impacto de un error.

En la revisión realizada no se encontraron evaluaciones sistemáticas de este patrón aplicado a la preparación de datos de prueba. [**VERIFICAR: confirmar con una búsqueda bibliográfica específica; si se confirma, registrarlo como vacío del estado del arte**]

2.5.4. Privacidad y costo al usar modelos de lenguaje

Enviar nombres de columnas, valores de muestra o esquemas de una base productiva a un servicio externo es en sí un tratamiento de datos personales, con los riesgos que ello implica. La lista de riesgos de aplicaciones con modelos de lenguaje de OWASP incluye la divulgación de información sensible (OWASP, 2025). Esto favorece los modelos que corren en infraestructura propia, compatibles con el principio de minimización de la Ley N.º 18.331, a costa de requisitos

de memoria y de calidad: el costo de las licencias de los modelos abiertos es nulo, pero el costo se traslada al hardware y al esfuerzo de ingeniería. La decisión concreta de qué modelo usar corresponde a la Etapa 2.

2.6. Integridad referencial y extracción de subconjuntos

Preservar las claves primarias y foráneas al sintetizar datos relacionales es el problema técnico más exigente que surge del relevamiento.

2.6.1. Claves primarias

Una clave primaria no tiene una distribución estadística que valga la pena aprender: un modelo generativo entrenado sobre una columna identificadora puede producir valores plausibles pero con colisiones y sin garantía de unicidad. Las estrategias habituales se resumen en la Tabla 2.8.

Estrategia	**Cuándo se usa**	**Problema**
Regenerar de forma secuencial	Claves subrogadas (autoincrementales)	Rompe cualquier clave foránea que apunte a ella, salvo que el mapeo se propague.
Tokenización determinista	Claves naturales (cédula, correo)	Requiere mantener y proteger la tabla de correspondencia, que es la información adicional que mantiene el dato como personal.
Hash con sal	Claves naturales sin necesidad de reversibilidad	Con dominios pequeños (la cédula) es invertible por fuerza bruta si la sal no es larga y secreta.
Cifrado que preserva el formato	Claves con formato validado por la aplicación	Requiere gestión de claves criptográficas.

Tabla 2.8: Estrategias de tratamiento de claves primarias.

Cualquiera sea la estrategia, la correspondencia debe aplicarse de forma consistente a todas las claves foráneas que referencian esa clave, y también a las referencias no declaradas (columnas con el mismo identificador pero sin restricción), algo frecuente en esquemas heredados.

2.6.2. Claves foráneas y estructura relacional

Para las claves foráneas se identifican tres enfoques.

- **Preservar la estructura y sintetizar solo los atributos.** Se mantienen filas, claves primarias y foráneas y se sintetizan las columnas de negocio. Es el más simple y seguro para la integridad, pero la estructura de referencias es en sí misma información: un cliente con un volumen de transacciones atípico es identificable por la cardinalidad de sus relaciones,

aunque todos sus atributos sean sintéticos. Es el equivalente, sobre el grafo relacional, del riesgo de *singling out*.

- **Sintetizar también la estructura relacional.** Los modelos relacionales de la Tabla 2.3 generan filas y relaciones. Es el área menos madura. Los sintetizadores jerárquicos tienen límites de escala documentados (en SDV, alrededor de cinco tablas y un nivel de profundidad (DataCebo, 2025a)), y los benchmarks específicos como SyntheRela existen justamente porque el área está poco evaluada (Hudovernik y cols., 2024). MOSTLY AI SDK, por su parte, entrena un único generador sobre varias tablas vinculadas (MOSTLY AI, 2025). [**VERIFICAR: confirmar con pruebas propias los límites reales de cada herramienta**]

- **Enfoque híbrido.** Se mantiene el grafo determinista de relaciones, se sintetizan los atributos y se ajusta la distribución de cardinalidades por remuestreo para romper patrones estructurales atípicos. Es una hipótesis de trabajo derivada del análisis: no está validada experimentalmente y su evaluación corresponde a la Etapa 2.

2.6.3. Extracción de subconjuntos

Una base productiva real puede tener cientos o miles de tablas, y extraer una base entera es inviable e innecesario. La extracción de subconjuntos (*subsetting*) exige elegir una o más tablas ancla y un criterio de filtro, recorrer las claves foráneas hacia las tablas padre y hacia las tablas hijas para mantener la integridad, copiar completas las tablas de referencia (catálogos, países, monedas) y resolver los ciclos de dependencia. Las plataformas comerciales como Tonic.ai incluyen esta capacidad (Tonic.ai, 2026); no se encontró una implementación de código abierto madura. [**VERIFICAR: confirmar con una búsqueda específica**]

Entre las dificultades prácticas están las claves foráneas no declaradas en la base (la integridad la mantiene la aplicación), las relaciones polimórficas (por ejemplo, un par tipo-identificador que apunta a distintas tablas), las tablas autorreferenciadas y la «explosión» del subconjunto: en esquemas muy conectados, seleccionar una fracción pequeña de una tabla ancla puede arrastrar gran parte de la base. Una forma de acotar el problema es tratar parte del esquema como *mock*: por ejemplo, tablas base muy referenciadas (calles, catálogos) se reemplazan por valores fijos cuando no son lo que se quiere probar.

2.6.4. Tipos de datos complejos

Los generadores tabulares tratan mal ciertos tipos de columna (Tabla 2.9).

Tipo	Comportamiento típico	Tratamiento posible
JSON, arreglos, XML	Mal soportados; se tratan como cadena opaca	Extraer campos relevantes a columnas, procesar y reensamblar, o aplicar reglas deterministas sobre claves conocidas.
Geoespaciales	No soportados	Generalización espacial (reducir la precisión de las coordenadas).
Binarios (BLOB)	Ignorados o pasados sin cambios	Riesgo alto, pueden contener documentos con datos personales; reemplazar por un archivo de relleno del mismo tamaño.
Texto libre	Tratado como categoría de alta cardinalidad, con malos resultados	Proceso separado: reconocimiento de entidades y redacción, o síntesis textual.
Enumerados	Bien soportados como categorías	Verificar que el generador no produzca valores fuera del dominio.
Fechas relacionadas	Se pierde la coherencia entre ellas	Restricción explícita (por ejemplo, fecha de baja posterior a la de alta).
Columnas cifradas o calculadas	No procesables o deben recalcularse	Excluir de la síntesis y recalcular al cargar.

Tabla 2.9: Tratamiento de tipos de datos complejos.

2.7. Criterios y dimensiones de evaluación

Evaluar una base de preproducción exige medir varias cosas a la vez, y ninguna herramienta relevada las cubre todas. La Tabla 2.10 propone seis dimensiones para el caso de estudio. Las métricas concretas se definirán en la Etapa 2.

Dimensión	Qué se quiere saber	Posibles medidas	Antecedentes
Privacidad	¿Puede reidentificarse a alguien?	Riesgo de *singling out*, *linkability* e *inference*; distancia al registro más cercano; coincidencias exactas; k-anonimato; ε si el generador usa DP-SGD.	Anonymeter, ARX, SynthEval
Fidelidad	¿Se parecen las distribuciones y relaciones a las originales?	Forma de cada columna; tendencias entre pares de columnas; similitud de cardinalidades y de correlaciones entre tablas conectadas.	SDMetrics, SyntheRela, SynthEval
Integridad referencial	¿Se respetan claves y restricciones?	Porcentaje de claves foráneas que resuelven; claves primarias duplicadas; restricciones violadas; carga sin errores.	Verificaciones en el propio motor
Utilidad para testing	¿Sirve para encontrar defectos?	Suite de pruebas existente que pasa y su cobertura; casos borde representados; reproducción de errores conocidos; planes de ejecución de consultas comparables.	No cubierta por las herramientas relevadas*
Trazabilidad	¿Se puede reconstruir y auditar el proceso?	Registro de la versión del esquema, la clasificación usada, las semillas, los parámetros y las decisiones humanas; reproducibilidad con la misma semilla.	Práctica de ingeniería a definir
Costo y esfuerzo	¿Cuánto cuesta producirlo?	Tiempo de entrenamiento y generación; memoria o GPU; costo de licencias o de uso de modelos; horas de configuración.	Medición propia

Tabla 2.10: Dimensiones de evaluación para el caso de estudio.

2.7.1. Utilidad para testing frente a utilidad para aprendizaje automático

La literatura sobre datos sintéticos tabulares mide la utilidad casi siempre como eficacia para entrenar modelos de aprendizaje automático, por ejemplo entrenando un clasificador con datos sintéticos y evaluándolo con datos reales (protocolo conocido como TSTR). Esa medida es adecuada para entrenar modelos, pero es poco relevante para testear software. Lo que necesita una base de preproducción es otra cosa: que cargue sin errores y cumpla las restricciones, que los valores pasen las validaciones de la aplicación, que la suite de pruebas existente siga pasando y con qué cobertura, que estén representados los valores nulos, vacíos y extremos que suelen disparar defectos, que los errores reportados en producción puedan reproducirse y que los planes de ejecución de las consultas sean comparables a los de producción. Este último punto es fácil de pasar por alto: una base con distribuciones de cardinalidad distorsionadas puede generar planes de consulta distintos y, por lo tanto, no detectar problemas de rendimiento. Las librerías de evaluación relevadas miden fidelidad estadística y eficacia para aprendizaje automático; no se encontraron métricas orientadas específicamente a la utilidad para testing. **[VERIFICAR: confirmar con una**

búsqueda bibliográfica en el área de generación de datos de prueba]

2.7.2. Cómo se mide el riesgo de privacidad

Además del diseño de tres ataques de Anonymeter (Sección 2.4.7), se usan medidas complementarias. La *distancia al registro más cercano* (DCR) compara cada registro sintético con el real más próximo; un valor bajo en sí no dice nada, pero si es sistemáticamente menor que la distancia a un conjunto de control retenido, indica sobreajuste. Los *ataques de inferencia de pertenencia* (Shokri y cols., 2017) intentan determinar si un registro formó parte del entrenamiento. Las *coincidencias exactas* entre filas sintéticas y reales son una verificación mínima, que debería dar cero. Y el k-anonimato del resultado o el valor de ε aportan medidas sintácticas o formales como complemento. Todas requieren planificar desde el inicio un conjunto de control de registros reales que no se use en el entrenamiento.

2.8. Bases de datos de referencia

Para probar las herramientas hacen falta bases de datos relacionales con claves foráneas, campos con aspecto de datos personales y un tamaño manejable. Ninguna de las candidatas es la base productiva de una organización, lo que es una limitación a declarar. La selección queda pendiente (Tabla 1.2); la Tabla 2.11 reúne las candidatas relevadas.

Base	**Descripción y uso previsto**	**Motor**
Sakila (Oracle, 2025), Pagila (Proyecto Pagila, 2025)	Alquiler de películas: clientes, direcciones, pagos y empleados en unas quince tablas relacionadas. Sakila es el ejemplo oficial de MySQL y Pagila su adaptación para PostgreSQL.	MySQL, PostgreSQL
Chinook (Proyecto Chinook, 2025)	Tienda de música: clientes, facturas y empleados. Disponible para varios motores.	Varios
AdventureWorks (Microsoft, 2025a)	Base empresarial de Microsoft, mucho más grande y compleja; útil para probar los límites de escala en esquemas de decenas de tablas.	SQL Server (adaptaciones a otros motores)
Adult / Census Income (Becker y Kohavi, 1996)	Tabla única que es el ejemplo canónico de la literatura de k-anonimato y privacidad diferencial.	Archivo
Synthea (Walonoski y cols., 2018)	Genera historias clínicas sintéticas con relaciones; interesante si el caso de estudio fuera del área de la salud.	Archivos
MIMIC-IV (Johnson y cols., 2023)	Datos clínicos reales ya desidentificados. Requiere solicitar acceso con credenciales, por lo que se deja para más adelante.	Archivos o PostgreSQL

Tabla 2.11: Bases de datos candidatas para las pruebas.

Sakila o Pagila son un punto de partida razonable por coincidir con los motores considerados (PostgreSQL y MySQL) y por tener datos con aspecto de personales. Para estresar el límite de tablas de los sintetizadores relacionales se

necesitaría una base más grande, como AdventureWorks. [**VERIFICAR: decidir la selección con la supervisión y registrar el criterio de elección**]

Capítulo 3

Conclusiones y Trabajo Futuro

3.1. Conclusiones del relevamiento

1. **Ninguna herramienta relevada cubre sola el proceso completo con una licencia utilizable en este trabajo.** Las plataformas comerciales que más se acercan (Tonic.ai, Delphix) son propietarias, de costo elevado y no inspeccionables; sirven como referencia funcional, no como base técnica.

2. **El ecosistema abierto cubre bien piezas aisladas y deja sin cubrir la decisión.** Hay herramientas maduras para enmascarar dentro del motor, para sintetizar datos, para detectar datos sensibles y para evaluar el resultado. Lo que está mucho menos resuelto es decidir qué proteger y cómo, sobre todo en esquemas relacionales.

3. **La evidencia sobre clasificar columnas con modelos de lenguaje es favorable pero limitada.** Dar contexto del esquema mejora la clasificación frente a las reglas en el estudio relevado, pero ese estudio usó un solo modelo en la nube, reporta falsos negativos todavía altos y los benchmarks de detección de datos personales en texto muestran desempeños absolutos bajos. No hay evidencia suficiente sobre modelos locales en bases relacionales.

4. **Los modelos de lenguaje no son una buena opción para generar filas**; sus usos más plausibles son la clasificación y la orquestación mediante salidas estructuradas. Para este último patrón no se encontraron evaluaciones sistemáticas.

5. **Un dato sintético no es anónimo por definición.** Cualquier propuesta debe incluir una evaluación de privacidad posterior a la generación, con un conjunto de control, y no solo una técnica de generación.

6. **Preservar la integridad referencial al sintetizar datos relacionales es el problema técnico más exigente** y el área menos madura. Los sintetizadores multi-tabla tienen límites de escala documentados, y la propia estructura de relaciones puede filtrar información.
7. **La utilidad de una base para testing de software es una dimensión distinta de su utilidad para entrenar modelos** y está poco cubierta por las herramientas y la literatura relevadas. Se identifica como un posible aporte propio del proyecto.
8. **El contexto es cambiante.** Las licencias, las adquisiciones y las guías regulatorias están en movimiento (SDV, Gretel, MOSTLY AI, las guías del EDPB), lo que obliga a preferir componentes con licencia permisiva y ejecución local, y a reverificar los datos antes de la defensa.

3.2. Requisitos preliminares

De las reuniones de seguimiento surgieron requisitos que se registran aquí para formalizarlos en la Etapa 2:

- Identificar, con apoyo de la normativa de protección de datos (Ley N.º 18.331 y GDPR), qué columnas deben anonimizarse obligatoriamente, y permitir a la persona usuaria decidir qué más proteger o conservar (por ejemplo, conservar el sexo o la cantidad de hijos por su valor para el análisis).
- Mantener a la persona usuaria en control: mostrarle el esquema, los nombres de las columnas, los tipos y los valores permitidos, y no automatizar por completo esa decisión.
- Como paso posterior, advertir del riesgo de reidentificación según lo elegido y señalar valores muy singulares (casos en que una sola persona cumple una condición).
- Preservar las relaciones entre entidades al anonimizar (por ejemplo, familiares que también tienen identificador propio en el sistema).
- Partir siempre de datos productivos y no solo del esquema, para no perder los casos raros que el esquema permite pero que existen en los datos; anonimizar primero y sintetizar después.
- No enviar datos sin anonimizar a servicios externos; preferir ejecución local.
- Permitir una desanonimización controlada, con la correspondencia protegida, para depurar errores.
- Trabajar sobre un subconjunto acotado de la base, con el resto del esquema tratado como *mock* cuando no es el foco de la prueba.
- La propuesta debe ser genérica dentro de las bases relacionales, parametrizable y extensible, y no una solución para un esquema particular.

3.3. Preguntas abiertas

1. ¿Cuánto mejora la clasificación de columnas sensibles al dar al modelo el contexto del esquema, usando un modelo local en lugar de uno en la nube?
2. ¿Qué medidas de utilidad para testing (suite de pruebas, casos borde, planes de ejecución) permiten decidir si una base de preproducción es útil?
3. ¿Cómo se relaciona el presupuesto de privacidad ε con esa utilidad para testing?
4. ¿Cuánta información identificatoria hay en la estructura de relaciones (las cardinalidades), aun cuando los atributos sean sintéticos?
5. ¿Es posible traducir reglas de negocio expresadas en lenguaje natural a restricciones verificables sobre un generador abierto?
6. ¿Cómo combinar la elección de la persona usuaria sobre qué anonimizar con la clasificación automática, y cómo informarle del riesgo de reidentificación?

3.4. Limitaciones y trabajo para la Etapa 2

Este informe tiene límites que conviene tener presentes. Es un relevamiento documental: las capacidades de las herramientas provienen de su documentación y de las publicaciones citadas, y todavía no están contrastadas con pruebas propias. Varias fuentes son preprints o guías en consulta, y el sector cambia con rapidez, por lo que los datos corresponden a setiembre y octubre de 2026. Y el análisis jurídico se limita a fijar un criterio técnico de referencia.

La Etapa 2 retomará estos antecedentes para el relevamiento, análisis y evaluación de propuestas y estrategias, y para la definición de una propuesta propia. Quedan para esa etapa: las pruebas de las herramientas con las bases de referencia seleccionadas (Sección 2.8), la concreción de las métricas de las dimensiones de la Tabla 2.10, la formalización de los requisitos de la Sección 3.2, y el diseño de una arquitectura y su plan de validación.

Referencias

Abadi, M., Chu, A., Goodfellow, I., McMahan, H. B., Mironov, I., Talwar, K., y Zhang, L. (2016). Deep learning with differential privacy. En *Proceedings of the ACM conference on computer and communications security (CCS)*.

Aggarwal, C. C. (2005). On k-anonymity and the curse of dimensionality. En *Proceedings of the 31st international conference on very large data bases (VLDB)*.

Agisha Ntwali, A., Rück, L., y Heckmann, M. (2025). *Detection of personal data in structured datasets using a large language model.* (LLM-DPM 2025; arXiv:2506.22305)

Article 29 Data Protection Working Party. (2014). *Opinion 05/2014 on anonymisation techniques (WP216)* (Inf. Téc. n.º 0829/14/EN). Comisión Europea.

Becker, B., y Kohavi, R. (1996). *Adult.* Descargado de https://archive.ics.uci.edu/dataset/2/adult (UCI Machine Learning Repository)

Borisov, V., Seßler, K., Leemann, T., Pawelczyk, M., y Kasneci, G. (2023). Language models are realistic tabular data generators. En *International conference on learning representations (ICLR)*.

Cai, K., Xiao, X., y Cormode, G. (2023). PrivLava: Synthesizing relational data with foreign keys under differential privacy. *Proceedings of the ACM on Management of Data (PACMMOD)*.

Carlini, N., Tramèr, F., Wallace, E., Jagielski, M., Herbert-Voss, A., Lee, K., … Raffel, C. (2021). Extracting training data from large language models. En *USENIX security symposium*.

Dalibo. (2025). *PostgreSQL anonymizer: masking and anonymization extension for PostgreSQL.* Descargado de https://postgresql-anonymizer.readthedocs.io/

DataCebo. (2023). *Updating the SDV license.* Descargado de https://datacebo.com/blog/sdv-bsl-license/ (Publicado el 14 de abril de 2023)

DataCebo. (2025a). *HMASynthesizer, SDV (documentación oficial).* Descargado de https://docs.sdv.dev/sdv/modeling/multi-table-synthesizers/hmasynthesizer.md

DataCebo. (2025b). *SDMetrics (documentación oficial).* Descargado de https://docs.sdv.dev/sdmetrics

Dwork, C., McSherry, F., Nissim, K., y Smith, A. (2006). Calibrating noise to sensitivity in private data analysis. En *Theory of cryptography conference*

(TCC).

Dwork, C., y Roth, A. (2014). The algorithmic foundations of differential privacy. *Foundations and Trends in Theoretical Computer Science*, *9*(3–4), 211–407.

European Data Protection Board. (2026). *Guidelines 02/2026 on anonymisation.* Borrador para consulta pública, adoptado el 7 de julio de 2026. https://www.edpb.europa.eu/system/files/2026-07/edpb_guidelines_202602_anonymisation_v1_en_0.pdf. (Consulta abierta hasta el 30 de octubre de 2026)

Giomi, M., Boenisch, F., Wehmeyer, C., y Tasnádi, B. (2023). A unified framework for quantifying privacy risk in synthetic data. En *Proceedings on privacy enhancing technologies (PoPETs)*. (arXiv:2211.10459)

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., … Bengio, Y. (2014). Generative adversarial nets. En *Advances in neural information processing systems (NeurIPS)*.

Hudovernik, V., Jurkovič, M., y Štrumbelj, E. (2024). *Benchmarking the fidelity and utility of synthetic relational data.* (arXiv:2410.03411)

Hudovernik, V., Xu, M., Shi, J., Šubelj, L., Ermon, S., Štrumbelj, E., y Leskovec, J. (2025). *RelDiff: Relational data generative modeling with graph-based diffusion models.* (arXiv:2506.00710)

Information Commissioner's Office. (2023). *Privacy-enhancing technologies (PETs).* Descargado de https://ico.org.uk/for-organisations/uk-gdpr-guidance-and-resources/data-sharing/privacy-enhancing-technologies/

Information Commissioner's Office. (2025). *Anonymisation.* Descargado de https://ico.org.uk/for-organisations/uk-gdpr-guidance-and-resources/data-sharing/anonymisation/

Jha, P. (2026). *PIIBench: A unified multi-source benchmark corpus for personally identifiable information detection.* (arXiv:2604.15776)

Johnson, A. E. W., y cols. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, *10*.

Kingma, D. P., y Welling, M. (2014). Auto-encoding variational Bayes. En *International conference on learning representations (ICLR)*.

Kotelnikov, A., Baranchuk, D., Rubachev, I., y Babenko, A. (2023). TabDDPM: Modelling tabular data with diffusion models. En *International conference on machine learning (ICML)*.

Krchova, I., Vargas Vieyra, M., Scriminaci, M., y Sidorenko, A. (2025). *Democratizing tabular data access with an open-source synthetic-data SDK.* (arXiv:2508.00718)

Lautrup, A. D., y cols. (2025). SynthEval: A framework for detailed utility and privacy evaluation of tabular synthetic data. *Data Mining and Knowledge Discovery*, *39*.

Li, N., Li, T., y Venkatasubramanian, S. (2007). t-closeness: Privacy beyond k-anonymity and l-diversity. En *Proceedings of the 23rd IEEE international conference on data engineering (ICDE)*.

Machanavajjhala, A., Kifer, D., Gehrke, J., y Venkitasubramaniam, M. (2007). l-diversity: Privacy beyond k-anonymity. *ACM Transactions on Knowledge Discovery from Data*, *1*(1), 3.

Microsoft. (2025a). *AdventureWorks sample databases.* Descargado de https://learn.microsoft.com/en-us/sql/samples/adventureworks-install-configure

Microsoft. (2025b). *Dynamic data masking (sql server).* Descargado de https://learn.microsoft.com/en-us/sql/relational-databases/security/dynamic-data-masking

Microsoft. (2025c). *Presidio: data protection and de-identification SDK.* https://github.com/microsoft/presidio. (Consultado en setiembre de 2026)

MOSTLY AI. (2025). *MOSTLY AI synthetic data SDK.* Descargado de https://github.com/mostly-ai/mostlyai

Oracle. (2025). *MySQL: Sakila sample database.* Descargado de https://dev.mysql.com/doc/sakila/en/

OWASP. (2025). *OWASP top 10 for large language model applications.* Descargado de https://genai.owasp.org/llm-top-10/

Pang, W., y cols. (2024). *ClavaDDPM: Multi-relational data synthesis with cluster-guided diffusion models.* (Advances in Neural Information Processing Systems (NeurIPS); arXiv:2405.17724)

Parlamento Europeo y Consejo de la Unión Europea. (2016). *Reglamento (ue) 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales (reglamento general de protección de datos).* (Diario Oficial de la Unión Europea, L 119)

Patki, N., Wedge, R., y Veeramachaneni, K. (2016). The Synthetic Data Vault. En *Ieee international conference on data science and advanced analytics (dsaa).*

Perforce. (2026). *Perforce Delphix Data Platform.* https://www.perforce.com/products/delphix. (Consultado en setiembre de 2026)

Prasser, F., y Kohlmayer, F. (2015). Putting statistical disclosure control into practice: The ARX data anonymization tool. En *Medical data privacy handbook.* Springer.

Proyecto Chinook. (2025). *Chinook database.* Descargado de https://github.com/lerocha/chinook-database

Proyecto Pagila. (2025). *Pagila: PostgreSQL port of the Sakila sample database.* Descargado de https://github.com/devrimgunduz/pagila

República Oriental del Uruguay. (2008). *Ley n.º 18.331 de Protección de Datos Personales y Acción de Habeas Data.* Diario Oficial. Complementada por el Decreto 414/009, el Decreto 64/020, la Ley 19.924 y la Ley 20.075.

Shokri, R., Stronati, M., Song, C., y Shmatikov, V. (2017). Membership inference attacks against machine learning models. En *IEEE symposium on security and privacy.*

Solatorio, A. V., y Dupriez, O. (2023). *REaLTabFormer: Generating realistic relational and tabular data using transformers.* (arXiv:2302.02041)

Sweeney, L. (2000). *Simple demographics often identify people uniquely* (Inf. Téc.). Carnegie Mellon University, Data Privacy Working Paper 3.

Sweeney, L. (2002). k-anonymity: A model for protecting privacy. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, *10*(5), 557–570.

TechCrunch. (2025). *Nvidia reportedly acquires synthetic data startup Gretel.* Descargado de https://techcrunch.com/2025/03/19/nvidia-reportedly-acquires-synthetic-data-startup-gretel (Publicado el 19 de marzo de 2025)

Tiwald, P., Krchova, I., Sidorenko, A., Vargas Vieyra, M., Scriminaci, M., y Platzer, M. (2025). *TabularARGN: A flexible and efficient auto-regressive framework for generating high-fidelity synthetic data.* (arXiv:2501.12012)

Tonic.ai. (2026). *Tonic.ai: plataforma de gestión y síntesis de datos de prueba.* Descargado de https://www.tonic.ai/

Tribunal de Justicia de la Unión Europea. (2025). *Sentencia de 4 de setiembre de 2025, EDPS contra SRB, asunto c-413/23 p.* Descargado de https://eur-lex.europa.eu/eli/C/2025/5551/oj/eng

Unidad Reguladora y de Control de Datos Personales. (2017). *Guía de criterios de disociación de datos personales (resolución n.º 68/017 del 26 de abril de 2017).* Descargado de https://www.gub.uy/unidad-reguladora-control-datos-personales/comunicacion/publicaciones/guia-criterios-disociacion-datos-personales/guia-criterios-disociacion-1

Walonoski, J., y cols. (2018). Synthea: An approach, method, and software mechanism for generating synthetic patients and the synthetic electronic health care record. *Journal of the American Medical Informatics Association*, *25*(3), 230–238.

Watson, D. S., Blesch, K., Kapar, J., y Wright, M. N. (2023). Adversarial random forests for density estimation and generative modeling. En *International conference on artificial intelligence and statistics (AISTATS).*

Xu, L., Skoularidou, M., Cuesta-Infante, A., y Veeramachaneni, K. (2019). Modeling tabular data using conditional GAN. En *Advances in neural information processing systems (NeurIPS).*

Zaratiana, U., Lewis, A., y Hurn-Maloney, G. (2026). *GLiNER2-PII: A multilingual model for personally identifiable information extraction.* (arXiv:2605.09973)

Zaratiana, U., Tomeh, N., Holat, P., y Charnois, T. (2024). *GLiNER: Generalist model for named entity recognition using bidirectional transformer.* (NAACL 2024; arXiv:2311.08526)

Anexo A

Glosario

Anonimización Resultado de un tratamiento que impide identificar a las personas con los medios razonablemente disponibles. Se logra con técnicas como la generalización o el ruido y se juzga con un análisis de riesgo.

Atributo sensible Dato cuya revelación puede causar daño a una persona identificada (salud, ingresos, afiliación, entre otros).

Cuasi-identificador Dato que por sí solo no identifica, pero cuya combinación con otros puede hacerlo (fecha de nacimiento, código postal, sexo).

DCR Distancia al registro real más cercano; mide qué tan parecido es cada registro sintético a uno real.

Decodificación restringida Técnica que obliga a un modelo de lenguaje a producir una salida que cumpla un formato, por ejemplo un JSON con un esquema dado.

DP-SGD Entrenamiento con privacidad diferencial: se recorta el gradiente de cada ejemplo y se le suma ruido calibrado.

Function calling Uso de un modelo de lenguaje para elegir qué función invocar y con qué parámetros, entre un conjunto de funciones definidas por el equipo.

Holdout (conjunto de control) Registros reales que se separan y no se usan para entrenar el generador, para poder medir si el modelo aprendió información específica.

Inference Riesgo de deducir con alta probabilidad el valor de un atributo a partir de otros.

Integridad referencial Propiedad por la cual toda clave foránea apunta a una clave primaria existente.

k-anonimato Propiedad por la cual cada registro es indistinguible de al menos $k-1$ más respecto de sus cuasi-identificadores.

Linkability Riesgo de vincular registros que corresponden a la misma persona o grupo.

Mock Reemplazo de una parte del sistema o de la base por valores fijos cuando no es lo que se quiere probar.

NER Reconocimiento de entidades nombradas: identificar en un texto nombres, identificadores, direcciones y similares.

PET Tecnología de mejora de la privacidad (*privacy-enhancing technology*).

Presupuesto de privacidad (ε) Parámetro de la privacidad diferencial: cuanto menor, mayor protección y más ruido.

Seudonimización Reemplazo de identificadores por referencias, guardando por separado la información que permite revertirlo. Sigue siendo dato personal.

Singling out Riesgo de aislar un registro que identifica a una persona.

Subsetting Extracción de un subconjunto coherente de una base, manteniendo la integridad referencial.

TSTR Protocolo de evaluación que entrena un modelo con datos sintéticos y lo prueba con datos reales (*train on synthetic, test on real*).